

Segmentación de clientes con Algoritmos de Aprendizaje Automatico no Supervisado

Ernestina Campos Llano
Universidad Nacional de Hurlingham

31 de julio de 2026

Índice

1. Introducción	3
1.1. Objetivo general	3
2. Marco teórico	3
2.1. K-means	3
2.2. DBSCAN	3
2.3. Métricas de evaluación de clustering	3
3. Metodología	3
3.1. Dataset	3
3.2. Limpieza de datos	4
4. Análisis exploratorio: distribución geográfica	4
4.1. Distribución de transacciones y facturación por país	5
4.2. Comparación de comportamiento entre países	6
4.3. Discusión de resultados	6

Resumen

1. Introducción

1.1. Objetivo general

2. Marco teórico

2.1. K-means

2.2. DBSCAN

2.3. Métricas de evaluación de clustering

3. Metodología

3.1. Dataset

En el trabajo se utiliza el conjunto de datos *Online Retail II*, publicado en el repositorio UCI Machine Learning Repository. Contiene el registro de transacciones de una tienda minorista con sede en el Reino Unido, especializada en la venta de artículos de regalo para todo tipo de ocasiones, con una base de clientes compuesta principalmente por mayoristas.

El dataset abarca transacciones realizadas entre diciembre de 2009 y diciembre de 2011. Está compuesto por las siguientes variables:

- **Invoice:** número de factura, identifica cada transacción.
- **StockCode:** código de producto.
- **Description:** descripción del producto.
- **Quantity:** cantidad de unidades vendidas por transacción.
- **InvoiceDate:** fecha y hora de la transacción.
- **Price:** precio unitario del producto.
- **Customer ID:** identificador único de cliente.
- **Country:** país del cliente.

El archivo original está compuesto por dos hojas de cálculo, correspondientes a los períodos 2009-2010 y 2010-2011 respectivamente. El módulo `cargarDatos.py` lee ambas hojas y las concatena en un único DataFrame antes de generar una copia local en formato `.csv`.

Para la carga de los datos se desarrolló el módulo `cargarDatos.py`, que lee el archivo original en formato Excel (`.xlsx`) y lo convierte a un archivo `.csv` que se guarda como una copia local. En las ejecuciones siguientes, el módulo verifica si ya existe el archivo `.csv` y en caso afirmativo lo utiliza directamente en lugar de volver a leer el Excel original. Este mecanismo reduce significativamente el tiempo de carga, dado que la lectura de archivos Excel de gran tamaño es considerablemente más lenta que la de archivos CSV de igual contenido.

El dataset original está compuesto por 1.067.371 registros y 8 columnas. Las fechas de las transacciones abarcan desde el 1 de diciembre de 2009 hasta el 9 de diciembre de 2011. Se identificaron 5942 clientes únicos y transacciones provenientes de 43 países distintos, con predominio de Reino Unido.

Un análisis inicial de calidad de datos reveló los siguientes puntos a resolver en la etapa de limpieza:

- **Valores nulos:** 243.007 registros (22,8 %) sin **Customer ID**, y 4382 registros sin **Description**.

- **Duplicados:** 34.335 filas duplicadas.
- **Cancelaciones:** 19.494 transacciones corresponden a cancelaciones, identificables porque su número de factura (**Invoice**) empieza con la letra **C**".
- **Valores negativos:** la columna **Quantity** presenta un mínimo de -80.995 unidades, y la columna **Price** un mínimo de -\$53.594,36.

3.2. Limpieza de datos

A partir del análisis inicial descrito en la sección anterior, se implementó el módulo `limpieza_datos.py`, encargado de limpiar el dataset. La función `limpiarDatos` aplica los siguientes filtros:

1. **Eliminación de registros sin Customer ID:** dado que las transacciones sin identificador de cliente no pueden asociarse a ningún segmento y se descartan.
2. **Eliminación de cancelaciones:** se eliminan las transacciones cuyo número de **Invoice** comienza con la letra "C", correspondientes a cancelaciones.
3. **Eliminación de valores inválidos:** se conservan únicamente los registros con **Quantity** y **Price** positivos, descartando así cantidades o precios negativos que no representan compras válidas.
4. **Eliminación de duplicados exactos:** se remueven las filas completamente duplicadas.

Para entender mejor el impacto de cada filtro, se armó la función `resumenLimpieza`, que cuenta por separado cuántas filas cumplen cada uno de estos motivos sobre el dataset original. Hay que tener en cuenta que estos motivos no son excluyentes: una misma fila puede cumplir varios a la vez, por ejemplo, no tener **Customer ID** y ser también una cancelación.

Cuadro 1: Cantidad de registros afectados por cada motivo de limpieza (dataset original).

Motivo	Registros afectados
Sin Customer ID	243.007
Cancelaciones (Invoice con «C»)	19.494
Quantity negativo	22.950
Price negativo	6.207

Luego de esta limpieza, el dataset pasó de 1.067.371 a 779.425 registros, es decir que se eliminó un 27,0 % de las filas originales. La cantidad de clientes únicos casi no cambió, pasando de 5942 a 5878, lo que muestra que la mayoría de los clientes tiene al menos una transacción válida después de la limpieza.

4. Análisis exploratorio: distribución geográfica

Como parte del análisis exploratorio inicial, se analizó cómo se distribuían las transacciones según el país de origen del cliente, con el objetivo de ver si había diferencias de comportamiento entre países que fueran relevantes.

Cuadro 2: Distribución de transacciones y facturación por país (top 10)

País	Importe total	% Importe	Filas	% Filas
United Kingdom	14,389,230	82.82	700,388	89.86
EIRE	616,570	3.55	15,565	2.00
Netherlands	554,038	3.19	5,085	0.65
Germany	425,020	2.45	16,432	2.11
France	348,769	2.01	13,511	1.73
Australia	169,284	0.97	1,789	0.23
Spain	108,333	0.62	3,662	0.47
Switzerland	100,062	0.58	3,005	0.39
Sweden	91,516	0.53	1,317	0.17
Denmark	68,581	0.39	778	0.10

4.1. Distribución de transacciones y facturación por país

El dataset contiene registros de 43 países, con una concentración muy marcada en el Reino Unido. La Tabla 2 resume, para los diez países con mayor facturación, la cantidad de filas y el importe total generado, en términos absolutos y porcentuales.

United Kingdom concentra el 89.86 % de las filas del dataset y el 82.82 % de la facturación total.

La Figura 1 muestra los 15 países con más transacciones. Como United Kingdom domina la escala del gráfico, se agrega también la Figura 2, sin United Kingdom, para poder ver mejor cómo se distribuye el resto de los países.




Figura 1: Top 15 países por cantidad de transacciones




Figura 2: Top 15 países por cantidad de transacciones (excluyendo United Kingdom)

4.2. Comparación de comportamiento entre países

Para profundizar en el comportamiento de los clientes en los diferentes países, se compararon pares de países, calculando para cada uno: cantidad de filas, facturas únicas, clientes únicos, importe promedio, cantidad promedio, precio promedio, ticket promedio por factura, e ítems promedio por factura.

Cuadro 3: Comparación: United Kingdom vs. Lithuania

	United Kingdom	Lithuania
Filas	700,388	154
Facturas únicas	33,541	6
Clientes únicos	5,350	1
Importe promedio (por línea)	20.54	31.77
Cantidad promedio (por línea)	12.18	14.97
Precio promedio	3.07	2.56
Ticket promedio por factura	429.00	815.45
Ítems promedio por factura	254.39	384.33

4.3. Discusión de resultados

Las comparaciones muestran un patrón que se repite en la mayoría de los pares de países analizados: los países con menos clientes y transacciones tienen un ticket promedio por factura más alto que aquellos que tienen más cantidad de clientes y transacciones. El caso más marcado es el de Netherlands frente a Germany (Tabla 6): con menos de un tercio de las filas (5,085 frente a 16,432), Netherlands tiene un ticket promedio 4.5 veces mayor (2,429.99 contra 538.68). Se ve un patrón parecido, aunque menos marcado, entre Japan y Switzerland (Tabla 7) y entre United

Cuadro 4: Comparación: France vs. Germany

	France	Germany
Filas	13,511	16,432
Facturas únicas	614	789
Clientes únicos	95	107
Importe promedio (por línea)	25.81	25.87
Cantidad promedio (por línea)	20.01	13.70
Precio promedio	4.29	3.59
Ticket promedio por factura	568.03	538.68
Ítems promedio por factura	440.21	285.37

Cuadro 5: Comparación: United Arab Emirates vs. Portugal

	United Arab Emirates	Portugal
Filas	383	2,356
Facturas únicas	11	93
Clientes únicos	4	24
Importe promedio (por línea)	24.03	23.58
Cantidad promedio (por línea)	15.25	11.64
Precio promedio	3.64	5.10
Ticket promedio por factura	836.61	597.36
Ítems promedio por factura	530.82	294.87

Kingdom y Lithuania (Tabla 3).

En el caso de France y Germany (Tabla 4): ambos países tienen una cantidad de filas y facturas similares entre sí (a diferencia de los pares anteriores, donde uno de los dos era claramente más chico). Consistente con el patrón general, sus valores de ticket promedio e importe promedio por ítem también son parecidos entre sí, lo que refuerza la idea de que la diferencia de ticket promedio está más asociada al volumen relativo de cada país que a otro factor.

La comparación entre United Arab Emirates y Portugal (Tabla 5) refuerza el mismo patrón: aunque United Arab Emirates tiene muchas menos filas, facturas y clientes que Portugal, su ticket promedio por factura es más alto (836.61 frente a 597.36) y tiene casi el doble de ítems promedio por factura (530.82 frente a 294.87).

La comparación más interesante es la de United Kingdom contra el resto del mundo (Tabla 8). United Kingdom concentra el 89.86 % de las transacciones, pero el resto del mundo tiene un ticket promedio por factura de 870.94, más del doble que United Kingdom (429.00), y también más ítems promedio por factura (578.05 frente a 254.39). Esto sugiere que los clientes fuera de Reino Unido tienen, en promedio, un perfil de compra más parecido al de un mayorista o distribuidor, mientras que dentro de Reino Unido el comportamiento se parece más al de un consumidor minorista.

Cuadro 6: Comparación: Netherlands vs. Germany

	Netherlands	Germany
Filas	5,085	16,432
Facturas únicas	228	789
Clientes únicos	22	107
Importe promedio (por línea)	108.96	25.87
Cantidad promedio (por línea)	75.49	13.70
Precio promedio	2.69	3.59
Ticket promedio por factura	2,429.99	538.68
Ítems promedio por factura	1,683.68	285.37

Cuadro 7: Comparación: Japan vs. Switzerland

	Japan	Switzerland
Filas	468	3,005
Facturas únicas	33	90
Clientes únicos	10	22
Importe promedio (por línea)	91.93	33.30
Cantidad promedio (por línea)	67.61	17.38
Precio promedio	2.01	3.82
Ticket promedio por factura	1,303.75	1,111.80
Ítems promedio por factura	958.88	580.30

Cuadro 8: Comparación: United Kingdom vs. Resto del mundo

	United Kingdom	Resto del mundo
Filas	700,388	79,037
Facturas únicas	33,541	3,428
Clientes únicos	5,350	529
Importe promedio (por línea)	20.54	37.77
Cantidad promedio (por línea)	12.18	25.07
Precio promedio	3.07	4.57
Ticket promedio por factura	429.00	870.94
Ítems promedio por factura	254.39	578.05