

Título

Autor:

Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)



Índice general

Índice de Figures	3
Índice de Tablas	5
1. Introducción	11
1.1. Motivación	11
1.2. Estado del Arte	11
1.3. Conjuntos de Datos	11
2. Metodología	13
2.0.1. Dataset	13
2.0.2. Limpieza de datos	14
2.1. Análisis exploratorio: distribución geográfica	14
2.1.1. Distribución de transacciones y facturación por país	14
2.1.2. Comparación de comportamiento entre países	15
2.2. Cálculo de RFM	17
2.2.1. Escalamiento de variables	18
2.3. Clustering	19
2.3.1. K-means	19
2.3.2. DBSCAN	20
2.3.3. HDBSCAN	20
3. Resultados y discusión	23
3.0.1. Resultados de K-means	23
3.0.2. Resultados de DBSCAN	24
3.0.3. Resultados de HDBSCAN	25
4. Conclusiones	27
Bibliografía	27

Índice de Figuras

2.1. Top 15 países por cantidad de transacciones	15
2.2. Top 15 países por cantidad de transacciones (excluyendo Reino Unido)	17
2.3. Método del codo para la selección de k	20
3.1. Jerarquía de clusters construida por HDBSCAN	25

Índice de Tablas

2.1. Cantidad de registros afectados por cada motivo de limpieza (dataset original).	14
2.2. Distribución de transacciones y facturación por país (top 10)	15
2.3. Comparación de métricas de compra entre países seleccionados	16
2.4. Comparación: Reino Unido vs. Resto del mundo	18
2.5. Estadísticas descriptivas de las variables RFM	18
2.6. Estadísticas descriptivas de las variables RFM luego del escalamiento	19
3.1. Resumen de clusters: K-means con $k = 4$	23
3.2. Resumen de clusters: K-means con $k = 5$	24
3.3. Resumen de clusters: DBSCAN (eps=0.2, min_puntos=5)	24
3.4. Resumen de clusters: HDBSCAN (min_cluster_size=500, min_samples=3)	25

Resumen

Capítulo 1

Introducción

1.1 Motivación

1.2 Estado del Arte

1.3 Conjuntos de Datos

Capítulo 2

Metodología

2.0.1 Dataset

En el trabajo se utiliza el conjunto de datos *Online Retail II*, publicado en el repositorio UCI Machine Learning Repository. Contiene el registro de transacciones de una tienda minorista con sede en el Reino Unido, especializada en la venta de artículos de regalo para todo tipo de ocasiones, con una base de clientes compuesta principalmente por mayoristas.

El dataset abarca transacciones realizadas entre diciembre de 2009 y diciembre de 2011. Está compuesto por las siguientes variables:

- **Factura:** número de factura, identifica cada transacción.
- **Código de Artículo:** código de producto.
- **Descripción:** descripción del producto.
- **Cantidad:** cantidad de unidades vendidas por transacción.
- **Fecha de Factura:** fecha y hora de la transacción.
- **Precio:** precio unitario del producto.
- **Cliente ID:** identificador único de cliente.
- **País:** país del cliente.

El archivo original está compuesto por dos hojas de cálculo, correspondientes a los períodos 2009-2010 y 2010-2011 respectivamente. El módulo `cargarDatos.py` lee ambas hojas y las concatena en un único DataFrame antes de generar una copia local en formato `.csv`.

Para la carga de los datos se desarrolló un procedimiento que lee el archivo original en formato Excel (`.xlsx`) y lo convierte a un archivo `.csv` que se guarda como una copia local. En las ejecuciones siguientes, el proceso verifica si ya existe el archivo `.csv` y en caso afirmativo lo utiliza directamente en lugar de volver a leer el Excel original. Este mecanismo reduce significativamente el tiempo de carga, dado que la lectura de archivos Excel de gran tamaño es considerablemente más lenta que la de archivos CSV de igual contenido.

El dataset original está compuesto por 1.067.371 registros y 8 características. Las fechas de las transacciones abarcan desde el 1 de diciembre de 2009 hasta el 9 de diciembre de 2011. Se identificaron 5942 clientes únicos y transacciones provenientes de 43 países distintos, con predominio de Reino Unido.

Un análisis inicial de calidad de datos reveló los siguientes puntos a resolver en la etapa de limpieza:

- **Valores nulos:** 243.007 registros (22,8 %) sin **Cliente ID** y 4382 registros (0,41 %) sin **Descripción**.

- **Duplicados:** 34.335 registros duplicados (3,22 %).
- **Cancelaciones:** 19.494 transacciones (1,83 %) corresponden a cancelaciones, identificables porque su número de factura (**Factura**) empieza con la letra “C”.
- **Valores negativos:** el atributo **Cantidad** presenta un mínimo de -80.995 unidades, y la columna **Precio** un mínimo de -\$53.594,36.

2.0.2 Limpieza de datos

A partir del análisis inicial descrito en la sección anterior, se procedió a limpiar el dataset, aplicando los siguientes filtros:

1. **Eliminación de registros sin Customer ID:** dado que las transacciones sin identificador de cliente no pueden asociarse a ningún segmento y se descartan.
2. **Eliminación de cancelaciones:** se eliminan las transacciones cuyo número de **Factura** comienza con la letra “C”, correspondientes a cancelaciones.
3. **Eliminación de valores inválidos:** se conservan únicamente los registros con **Cantidad** y **Precio** positivos, descartando así cantidades o precios negativos que no representan compras válidas.
4. **Eliminación de duplicados exactos:** se remueven los registros completamente duplicados.

Para entender mejor el impacto de cada filtro, podemos observar la tabla 2.1 que cuenta por separado cuántos registros cumplen cada uno de estos motivos sobre el dataset original. Hay que tener en cuenta que estos motivos no son excluyentes: un mismo registro puede cumplir varios a la vez, por ejemplo, no tener **Cliente ID** y ser también una cancelación.

Tabla 2.1: Cantidad de registros afectados por cada motivo de limpieza (dataset original).

Motivo	Registros afectados
Sin Cliente ID	243.007
Cancelaciones (Factura con “C”)	19.494
Cantidad negativo	22.950
Precio negativo	6.207

Luego de esta limpieza, el dataset pasó de 1.067.371 a 779.425 registros, es decir que se eliminó un 27,0 % de los registros originales. La cantidad de clientes únicos casi no cambió, pasando de 5942 a 5878, lo que muestra que la mayoría de los clientes tiene al menos una transacción válida después de la limpieza.

2.1 Análisis exploratorio: distribución geográfica

Como parte del análisis exploratorio inicial, se analizó cómo se distribuían las transacciones según el país de origen del cliente, con el objetivo de ver si había diferencias de comportamiento entre países que fueran relevantes.

2.1.1 Distribución de transacciones y facturación por país

El dataset contiene registros de 43 países pero, como se puede observar en la tabla 2.2, hay una concentración muy marcada en el Reino Unido. El mismo concentra el 89.86 % de los registros del dataset y el 82.82 % de la facturación total.

Tabla 2.2: Distribución de transacciones y facturación por país (top 10)

País	Importe total	% Importe	Filas	% Filas
Reino Unido	14,389,230	82.82	700,388	89.86
Irlanda	616,570	3.55	15,565	2.00
Países Bajos	554,038	3.19	5,085	0.65
Alemania	425,020	2.45	16,432	2.11
Francia	348,769	2.01	13,511	1.73
Australia	169,284	0.97	1,789	0.23
España	108,333	0.62	3,662	0.47
Suiza	100,062	0.58	3,005	0.39
Suecia	91,516	0.53	1,317	0.17
Dinamarca	68,581	0.39	778	0.10

La Figura 2.1 muestra los 15 países con más transacciones. Como Reino Unido domina la escala del gráfico, se agrega también la Figura 2.2, sin Reino Unido, para poder ver mejor cómo se distribuye el resto de los países.




Figura 2.1: Top 15 países por cantidad de transacciones

2.1.2 Comparación de comportamiento entre países

Para ver si el comportamiento de compra cambia según el país, se compararon algunos de distintas regiones, tanto en cantidad de transacciones como en el valor de las mismas. En la Tabla 2.3 se presentan estas métricas para una selección de países de distinto tamaño y ubicación geográfica.

Las comparaciones muestran un patrón que se repite en la mayoría de los pares de países analizados: los países con menos clientes y transacciones tienen un ticket promedio por factura más alto que aquellos

Tabla 2.3: Comparación de métricas de compra entre países seleccionados

	Reino Unido	Lituania	Francia	Alemania	Emiratos Árabes	Portugal	Países Bajos	Japon	Suiza
Registros	700,388	154	13,511	16,432	383	2,356	5,085	468	3,005
Facturas únicas	33,541	6	614	789	11	93	228	33	90
Clientes únicos	5,350	1	95	107	4	24	22	10	22
Importe promedio (por línea)	20.54	31.77	25.81	25.87	24.03	23.58	108.96	91.93	33.30
Cantidad promedio (por línea)	12.18	14.97	20.01	13.70	15.25	11.64	75.49	67.61	17.38
Precio promedio	3.07	2.56	4.29	3.59	3.64	5.10	2.69	2.01	3.82
Ticket promedio por factura	429.00	815.45	568.03	538.68	836.61	597.36	2,429.99	1,303.75	1,111.80
Ítems promedio por factura	254.39	384.33	440.21	285.37	530.82	294.87	1,683.68	958.88	580.30




Figura 2.2: Top 15 países por cantidad de transacciones (excluyendo Reino Unido)

que tienen más cantidad de clientes y transacciones. El caso más marcado es el de Países Bajos frente a Alemania: con menos de un tercio de los registros (5,085 frente a 16,432), Países Bajos tiene un ticket promedio 4.5 veces mayor (2,429.99 contra 538.68). El caso de Francia y Alemania, ambos países tienen una cantidad de registros y facturas similares entre sí, es consistente con el patrón general, sus valores de ticket promedio e importe promedio por ítem también son parecidos entre sí, lo que refuerza la idea de que la diferencia de ticket promedio está más asociada al volumen relativo de cada país que a otro factor.

La comparación entre Reino Unido y el resto del mundo, presentada en la Tabla 2.4, resulta particularmente interesante. Reino Unido concentra el 89.86 % de las transacciones, pero el resto del mundo tiene un ticket promedio por factura de 870.94, más del doble que Reino Unido (429.00), y también más ítems promedio por factura (578.05 frente a 254.39). Esto sugiere que los clientes fuera de Reino Unido tienen, en promedio, un perfil de compra más parecido al de un mayorista o distribuidor, mientras que dentro de Reino Unido el comportamiento se parece más al de un consumidor minorista.

2.2 Cálculo de RFM

A partir del dataset limpio y filtrado solamente con los registros pertenecientes a Reino Unido, se calcularon para cada cliente las tres variables que componen el modelo RFM:

- **Recencia:** cantidad de días transcurridos entre la fecha de la última compra del cliente y una fecha de referencia fija, correspondiente al día posterior a la última transacción registrada en el dataset.
- **Frecuencia:** cantidad de facturas únicas asociadas al cliente, es decir, la cantidad de compras distintas que realizó.
- **Monto:** suma total del importe de todas las transacciones del cliente.

Tabla 2.4: Comparación: Reino Unido vs. Resto del mundo

	Reino Unido	Resto del mundo
Filas	700,388	79,037
Facturas únicas	33,541	3,428
Clientes únicos	5,350	529
Importe promedio	20.54	37.77
Cantidad promedio	12.18	25.07
Precio promedio	3.07	4.57
Importe promedio por factura	429.00	870.94
Ítems promedio por factura	254.39	578.05

Este cálculo se realizó únicamente sobre los clientes de Reino Unido, dado que, como se discutió en la sección anterior, este segmento concentra la enorme mayoría de los registros y presenta un comportamiento de compra distinto al del resto del mundo, más parecido al de un consumidor minorista. El resultado es un conjunto de 5.350 clientes únicos, cada uno caracterizado por sus tres métricas RFM. La Tabla 2.5 resume la distribución estadística de estas variables.

Tabla 2.5: Estadísticas descriptivas de las variables RFM

	Recencia	Frecuencia	Monto
Media	203.00	6.27	2,689.58
Desvío estándar	209.96	12.00	11,706.53
Mínimo	1	1	2.95
25 %	26	1	330.20
50 % (mediana)	98.5	3	829.44
75 %	382	7	2,156.25
Máximo	739	336	580,987.04

Las tres variables tienen una distribución bastante asimétrica: hay una diferencia grande entre la mediana, la media y el máximo. Esto se ve más que nada en Monto, donde la mediana es de \$829,44, la media sube a \$2.689,58 y el máximo llega a \$580.987,04. Esa diferencia tan grande muestra que hay clientes que compran mucho más que el resto.

2.2.1 Escalamiento de variables

Dado que las tres variables RFM se encuentran en escalas muy distintas entre sí (días, cantidad de compras, monto en dólares), fue necesario estandarizarlas antes de aplicar cualquier algoritmo de clustering. Si no se hacía esto, el Monto iba a dominar el cálculo de distancias entre clientes, ya que tiene una magnitud mucho mayor que la Recencia o la Frecuencia, y eso iba a distorsionar los resultados. Para esto se aplicó una estandarización de tipo *z-score*, que a cada variable le resta su media y la divide por su desvío estándar, para que las tres queden centradas en cero y con varianza 1.

Tabla 2.6: Estadísticas descriptivas de las variables RFM luego del escalamiento

	Recencia	Frecuencia	Monto
Media	≈ 0	≈ 0	≈ 0
Desvío estándar	1.00	1.00	1.00
Mínimo	-0.96	-0.44	-0.23
25 %	-0.84	-0.44	-0.20
50 % (mediana)	-0.50	-0.27	-0.16
75 %	0.85	0.06	-0.05
Máximo	2.55	27.49	49.40

Se observa en la Tabla 2.6 que, aunque el escalamiento logra que las tres variables queden en un rango comparable en su parte central (media 0, desvío 1), los valores máximos de Frecuencia y Monto siguen siendo extremos (27.49 y 49.40 respectivamente). Esto confirma que la asimetría de estas variables no se corrigió del todo con la estandarización, sino que responde a la presencia de un pequeño grupo de clientes con un comportamiento de compra muy por encima del resto.

2.3 Clustering


El objetivo general de este trabajo es comparar el desempeño de k -medias y DBSCAN para la segmentación de clientes en un contexto de *e-commerce*, evaluando métricas internas e interpretando las características de cada uno de los segmentos. Además de estos dos algoritmos, se agregó HDBSCAN debido a que este algoritmo resuelve algunas de las limitaciones de DBSCAN, ya que no necesita un valor fijo de `eps` y se adapta mejor a densidades variables dentro del dataset.

En las siguientes subsecciones se describe cómo se aplicó cada uno de los tres algoritmos sobre las variables RFM escaladas, y qué criterios se utilizaron para seleccionar sus respectivos parámetros.

2.3.1 K-means

El primer algoritmo aplicado fue K-means, un método de clustering particional que agrupa las observaciones en k clusters, buscando minimizar la distancia entre cada punto y el centroide de su cluster. A diferencia de DBSCAN y HDBSCAN, K-means requiere que se especifique de antemano la cantidad de clusters a formar, por lo que el primer paso fue determinar un valor adecuado de k . Para esto se utilizó el método del codo, que consiste en ejecutar el algoritmo con distintos valores de k y registrar, en cada caso, la inercia resultante (la suma de las distancias al cuadrado entre cada punto y su centroide). A medida que k aumenta, la inercia disminuye de forma natural, pero llega un punto en el que agregar clusters adicionales deja de aportar una mejora significativa. Ese punto de quiebre, visualizado como un `godo`.^{en} el gráfico, se toma como una buena referencia para elegir k .

La Figura 2.3 muestra la inercia obtenida para valores de k entre 2 y 10. Se ve una caída pronunciada hasta $k = 4$ / $k = 5$ y, a partir de ahí la curva se va aplanando considerablemente. Tomando esto como referencia, se probó el algoritmo tanto con $k = 4$ como con $k = 5$, para comparar ambas segmentaciones y evaluar cuál resulta más interpretable y mejor separada según las métricas internas.

Figura 2.3: Método del codo para la selección de k

2.3.2 DBSCAN

El segundo algoritmo aplicado fue DBSCAN, un método de clustering basado en densidad que agrupa los puntos que están suficientemente cerca entre sí, y marca como ruido a los que quedan aislados. A diferencia de K-means, DBSCAN no necesita que se le indique de antemano la cantidad de clusters a formar; en cambio, requiere dos parámetros: **eps**, la distancia máxima entre dos puntos para que se consideren vecinos, y **min_puntos**, la cantidad mínima de vecinos que necesita un punto para ser considerado parte de un cluster. Para elegir estos parámetros se hizo una búsqueda combinando distintos valores de **eps** y **min_puntos**, y para cada combinación se registró la cantidad de clusters formados y la cantidad (y porcentaje) de puntos clasificados como ruido. Las primeras corridas, con valores de **eps** más altos, agrupaban a casi todos los clientes en un único cluster gigante, mientras que valores muy bajos de **eps** fragmentaban el dataset en decenas de clusters de apenas 3 o 4 clientes cada uno. Ninguno de estos dos extremos resulta útil para una segmentación interpretable. Se buscó entonces un punto intermedio que diera una cantidad razonable de clusters, con tamaños más parejos entre sí y sin un porcentaje de ruido excesivo. La combinación elegida fue **eps**=0.2 y **min_puntos**=5, que resultó en 4 clusters y un 3,40 % de puntos clasificados como ruido.

2.3.3 HDBSCAN

El tercer algoritmo que se aplicó fue HDBSCAN. A diferencia de DBSCAN, no hace falta fijarle un valor de **eps** de antemano; en cambio, construye una jerarquía de clusters a distintos niveles de densidad y selecciona automáticamente los clusters más estables de esa jerarquía. El parámetro principal es **min_cluster_size**, el tamaño mínimo que tiene que tener un grupo para considerarse un cluster; también se puede ajustar **min_samples**, que regula qué tan estricto es el algoritmo a la hora de decidir qué es ruido. Al igual que con DBSCAN, se hizo una búsqueda combinando distintos valores de **min_cluster_size** y **min_samples**. Con valores bajos de **min_cluster_size** (entre 10 y 100), el algoritmo formaba muchos clusters chicos, entre 50 y 115, algo poco útil para una segmentación interpretable. A medida que se subió **min_cluster_size**, la cantidad de clusters bajó de forma consistente, hasta llegar a valores más manejables (4 a 7 clusters) con **min_cluster_size** entre 300 y 500. Un aspecto que se mantuvo constante en toda la búsqueda fue el porcentaje de ruido, que se movió siempre entre 20 % y 39 % sin importar mucho la combinación de parámetros elegida. La combinación final elegida fue **min_cluster_size**=500 y **min_samples**=3, que dio 5 clusters con un 32,90 % de ruido. Este nivel de ruido puede interpretarse no como un error en la elección de parámetros, sino como una característica

real de los datos: HDBSCAN identifica que una parte considerable de los clientes no encaja de forma clara en ningún grupo, algo que K-means no muestra porque fuerza a todos los puntos a pertenecer a algún cluster.

Capítulo 3

Resultados y discusión

3.0.1 Resultados de K-means

Se ejecutó K-means con $k = 4$ y con $k = 5$, tal como se planteó en la metodología. Para cada cluster se calcularon los promedios de Recencia, Frecuencia y Monto, para poder interpretar qué tipo de cliente representa cada grupo.

K-means con $k = 4$

Tabla 3.1: Resumen de clusters: K-means con $k = 4$

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
0	1,842	462.79	2.19	683.60
1	34	26.26	104.62	80,479.43
2	3,473	67.00	7.43	2,825.44
3	1	1.00	145.00	580,987.04

Como podemos ver en la Tabla 3.1, el cluster 2 es el más numeroso, con 3.473 clientes: compran cada dos meses aproximadamente y gastan en promedio \$2.825,44, un perfil de cliente activo y regular. El cluster 0, con 1.842 clientes, agrupa a quienes hace mucho que no compran (462 días en promedio) y con un gasto bajo, lo que sugiere clientes inactivos o perdidos. El cluster 1, más chico (34 clientes), es el grupo de mayor valor: compran seguido (más de 100 facturas en promedio) y gastan muy por encima del resto, cerca de \$80.479 en promedio. Por último, el cluster 3 queda formado por un único cliente, con un monto total de \$580.987,04 y 145 facturas, muy por encima de cualquier otro cliente de la base. Este resultado es consistente con lo discutido en la sección de escalamiento, donde ya se había identificado la presencia de un cliente con valores de compra extremos respecto al resto.

K-means con $k = 5$ Tabla 3.2: Resumen de clusters: K-means con $k = 5$

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
0	3,240	74.82	5.36	1,794.78
1	21	23.86	125.62	103,602.85
2	1,773	470.49	2.17	678.72
3	315	28.48	30.31	14,647.99
4	1	1.00	145.00	580,987.04

Por ootro lado, podemos ver en la Tabla 3.2 que con $k = 5$, los clusters de clientes inactivos (cluster 2) y de clientes regulares (cluster 0) se mantienen prácticamente iguales a los obtenidos con $k = 4$. La diferencia más importante está en el cluster de alto valor que teníamos con $k = 4$ el cual aquí se divide en dos. Por un lado queda un grupo chico de 21 clientes con un comportamiento de compra extremo, con 125 facturas y \$103.602 de gasto promedio. Por otro lado queda un grupo más grande, de 315 clientes, que también compran seguido y gastan bastante (30 facturas y \$14.647,99 en promedio), pero no tanto como el grupo anterior. Esto permite ver con más detalle a los clientes de mayor valor, algo que con $k = 4$ quedaba todo junto en un solo cluster. Al igual que con $k = 4$, aparece el cluster 4 que contiene solamente al mismo cliente con valores muy altos.

3.0.2 Resultados de DBSCAN

Tabla 3.3: Resumen de clusters: DBSCAN (eps=0.2, min_puntos=5)

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
Ruido (-1)	182	126.33	42.05	32,350.80
0	5,153	205.49	4.98	1,638.17
1	7	324.57	12.00	4,051.40
2	4	71.50	28.50	3,881.86
3	4	405.25	11.50	4,004.72

En la Tabla 3.3, que muestra el resumen de los clusters que se obtuvo con estos parámetros, incluyendo el grupo de ruido (etiqueta -1), se ve el problema: el cluster 0 se queda con 5.153 de los 5.350 clientes, casi todos los registros. Los clusters 1, 2 y 3 son grupos de 4 a 7 clientes solamnete, así que no sirven mucho para segmentar. Lo más llamativo pasa en el grupo de ruido. Esos 182 clientes tienen en promedio 42 compras y \$32.350,80 de monto, muy por encima del resto. O sea, DBSCAN no armó un cluster para los clientes de mayor valor, sino que los dejó afuera como ruido, porque no cumplían el criterio de densidad que fijan `eps` y `min_puntos`.

Esto muestra una limitación de DBSCAN con este tipo de datos: como usa un solo valor de `eps` para todo el dataset, no logra adaptarse tanto a la zona densa de clientes habituales como a los clientes con comportamiento extremo. Estos últimos terminan casi todos como ruido en vez de agruparse. Esta limitación es la que lleva a probar HDBSCAN en la siguiente sección.

3.0.3 Resultados de HDBSCAN

Tabla 3.4: Resumen de clusters: HDBSCAN (min_cluster_size=500, min_samples=3)

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
Ruido (-1)	1,760	227.15	13.00	6,401.98
0	550	48.21	7.20	2,176.17
1	1,146	122.09	3.74	1,072.27
2	520	108.38	2.00	599.32
3	627	133.36	1.00	300.04
4	747	508.52	1.00	262.74

A diferencia de DBSCAN, se puede observar en la Tabla 3.4 que acá los clusters tienen tamaños mucho más parejos, entre 520 y 1.146 clientes cada uno, y se pueden diferenciar bastante bien entre sí. El cluster 0 agrupa a los clientes más activos: compraron hace poco (48 días en promedio) y con una frecuencia relativamente alta (7.2 compras). El cluster 4, en el otro extremo, junta a los clientes más inactivos: hace más de 500 días que no compran y solo hicieron una compra en total. Los clusters 2 y 3 son parecidos entre sí, ambos con clientes de baja frecuencia (1 a 2 compras) y montos bajos, pero se diferencian en la recencia. El grupo de ruido vuelve a ser el más interesante: son 1.760 clientes, casi un tercio de los registros totales, con un monto promedio de \$6.401,98, muy por encima de cualquiera de los clusters formados. Esto confirma lo que se planteó en la metodología: HDBSCAN no fuerza a estos clientes de comportamiento más variado a entrar en algún grupo, sino que los deja afuera como puntos que no encajan claramente en ninguna densidad definida. A diferencia de DBSCAN, acá el grupo de ruido no se lleva puestos a los clientes de mayor valor de forma tan desproporcionada, sino que representa un conjunto más amplio y heterogéneo de clientes con comportamientos atípicos.




Figura 3.1: Jerarquía de clusters construida por HDBSCAN

La Figura 3.1 muestra el árbol condensado que construye HDBSCAN a partir del árbol de expansión mínima. En esta figura, el eje vertical representa el valor de λ (inversamente proporcional a la distancia),

y el ancho de cada rama indica la cantidad de puntos que la componen. Se puede ver cómo, a medida que aumenta λ es decir, a medida que se pide más densidad, todos los clientes se van separando en ramas cada vez más finas. Al principio del gráfico se desprende una rama ancha que junta a la mayoría de los clientes, y más abajo esa rama se divide en varias más chicas que llegan hasta el final del árbol. Esas son las que HDBSCAN termina eligiendo como clusters finales. Las ramas que se cortan antes de llegar al final son agrupaciones que el algoritmo no consideró lo bastante estables como para ser un cluster, y esos puntos terminan como ruido.

Capítulo 4

Conclusiones