

Título

Autor:

Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)



Índice general

Índice de Figures	2
Índice de Tablas	3
1. Introducción	6
1.1. Motivación	6
1.2. Estado del Arte	6
2. Metodología	7
2.1. Conjunto dec datos	7
2.1.1. Limpieza de datos	8
2.1.2. Análisis exploratorio: distribución geográfica	8
2.1.3. Distribución de transacciones y facturación por país	9
2.1.4. Comparación de comportamiento entre países	10
2.2. Cálculo de RFM	10
2.2.1. Escalamiento de variables	12
2.3. <i>Clustering</i>	13
2.3.1. K-means	14
2.3.2. DBSCAN	14
2.3.3. HDBSCAN	15
2.4. Métricas de calidad	16
3. Resultados y discusión	19
3.1. Resultados de RFM escalado	19
3.2. Resultados de K-means	20
3.3. Resultados de DBSCAN	23
3.4. Resultados de HDBSCAN	25
3.5. Evaluación de los modelos	28
4. Conclusiones	40
Bibliografía	41

Índice de Figuras

2.1. Top 15 países por cantidad de transacciones	9
2.2. Top 15 países por cantidad de transacciones (excluyendo Reino Unido)	10
2.3. Distribución de las variables RFM escaladas.	13
2.4. Método del codo para la selección de k	14
3.1. Distribución de clientes según RFM.	19
3.2. Distribución de clientes según K-Means: $k=4$	20
3.3. Clusters ($k=4$) según Recencia y Frecuencia.	21
3.4. Clusters ($k=4$) según Frecuencia y Monto.	22
3.5. Clusters ($k=4$) según Frecuencia y Monto, con zoom.	23
3.6. Clusters ($k=4$) según Recencia y Monto.	24
3.7. Clusters ($k=4$) según Recencia y Monto, con zoom.	25
3.8. Distribución de clientes según K-Means: $k=5$	26
3.9. Clusters ($k=5$) según Recencia y Frecuencia.	27
3.10. Clusters ($k=5$) según Frecuencia y Monto.	28
3.11. Clusters ($k=5$) según Frecuencia y Monto, con zoom.	29
3.12. Clusters ($k=5$) según Recencia y Monto.	29
3.13. Clusters ($k=5$) según Recencia y Monto, con zoom.	30
3.14. Distribución de clientes según DBSCAN.	30
3.15. Clusters DBSCAN según Recencia y Frecuencia.	31
3.16. Clusters DBSCAN según Frecuencia y Monto.	31
3.17. Clusters DBSCAN según Recencia y Monto.	32
3.18. Distribución de clientes según HDBSCAN - $min_cluster_size = 500, min_samples = 3$	32
3.19. Clusters HDBSCAN según Recencia y Frecuencia.	33
3.20. Clusters HDBSCAN según Frecuencia y Monto.	33
3.21. Clusters HDBSCAN según Frecuencia y Monto, con zoom.	34
3.22. Clusters HDBSCAN según Recencia y Monto.	34
3.23. Clusters HDBSCAN según Recencia y Monto, con zoom.	35
3.24. Jerarquía de clusters construida por HDBSCAN	35
3.25. Distribución de clientes según HDBSCAN - $min_cluster_size = 200, min_samples = 1$	36
3.26. Clusters HDBSCAN (200/1) según Recencia y Frecuencia.	37
3.27. Clusters HDBSCAN (200/1) según Frecuencia y Monto.	37
3.28. Clusters HDBSCAN (200/1) según Frecuencia y Monto, con zoom.	38
3.29. Clusters HDBSCAN (200/1) según Recencia y Monto.	38
3.30. Clusters HDBSCAN (200/1) según Recencia y Monto, con zoom.	39

Índice de Tablas

2.1. Cantidad de registros afectados por cada motivo de limpieza (dataset original).	8
2.2. Distribución de transacciones y facturación por país (top 10)	9
2.3. Comparación de métricas de compra entre países seleccionados	11
2.4. Comparación: Reino Unido vs. Resto del mundo	12
2.5. Estadísticas descriptivas de las variables RFM	12
2.6. Estadísticas descriptivas de las variables RFM luego del escalamiento	13
2.7. Grid search de parámetros para DBSCAN.	15
2.8. Grid search de parámetros para HDBSCAN.	16
3.1. Resumen de clusters: K-means con $k = 4$	20
3.2. Resumen de clusters: K-means con $k = 5$	22
3.3. Resumen de clusters: DBSCAN (eps=0.2, min_puntos=5)	23
3.4. Resumen de clusters: HDBSCAN (min_cluster_size=500, min_samples=3)	25
3.5. Perfil de los clusters obtenidos con HDBSCAN ($min_cluster_size=200$, $min_samples=1$).	36
3.6. Comparación de métricas de evaluación entre los distintos modelos.	36

Resumen

Capítulo 1

Introducción

1.1 Motivación

En la actualidad, las plataformas de comercio electrónico (e-commerce) generan un volumen masivo y constante de datos sobre las transacciones de sus usuarios. Sin embargo, disponer de una gran cantidad de datos no implica necesariamente contar con información útil. El principal desafío reside en transformar esos registros transaccionales en conocimiento práctico que sirva para orientar la toma de decisiones estratégicas. En un mercado competitivo, comprender cómo se comportan los clientes, con qué frecuencia compran y cuánto gastan resulta fundamental para diseñar estrategias de retención, optimizar recursos de marketing y mejorar el valor a largo plazo de la base de clientes. Para abordar este análisis, es habitual recurrir a la segmentación mediante el modelo RFM (Recencia, Frecuencia y Monto) en combinación con algoritmos de aprendizaje no supervisado (clustering). Esta metodología permite agrupar a los clientes de forma automática según la similitud de sus patrones de compra. Sin embargo, la aplicación de estos algoritmos en conjuntos de datos reales de e-commerce presenta complejidades particulares. Las métricas suelen mostrar una marcada asimetría, con una gran concentración de clientes de bajo consumo y un grupo reducido de compradores mayoristas o atípicos (outliers) que registran valores extremadamente altos. Teniendo esto en cuenta, los algoritmos tradicionales como K-means, aunque muy extendidos por su sencillez y rapidez, pueden verse afectados por la presencia de estos valores extremos o por la asunción de que los grupos tienen formas geométricas regulares. Por su parte, las alternativas basadas en densidad, como DBSCAN e HDBSCAN, proponen en teoría una mayor flexibilidad para identificar agrupaciones de formas complejas y aislar observaciones atípicas sin forzarlas a pertenecer a un clúster. La motivación de este trabajo surge de la necesidad de evaluar en la práctica el desempeño de estos tres enfoques sobre un conjunto de datos real (Online Retail II). El objetivo es determinar en qué medida las métricas cuantitativas de calidad matemática coinciden con la utilidad real de cada segmentación para el negocio, identificando qué algoritmo logra el equilibrio más conveniente entre precisión técnica e interpretabilidad comercial.

1.2 Estado del Arte

Capítulo 2

Metodología

2.1 Conjunto dec datos

En el trabajo se utiliza el conjunto de datos *Online Retail II*, publicado en el repositorio UCI Machine Learning Repository. Contiene el registro de transacciones de una tienda minorista con sede en el Reino Unido, especializada en la venta de artículos de regalo para todo tipo de ocasiones, con una base de clientes compuesta principalmente por mayoristas.

El dataset abarca transacciones realizadas entre diciembre de 2009 y diciembre de 2011. Está compuesto por las siguientes variables:

- **Factura:** número de factura, identifica cada transacción.
- **Codigo de Artículo:** código de producto.
- **Descripción:** descripción del producto.
- **Cantidad:** cantidad de unidades vendidas por transacción.
- **Fecha de Factura:** fecha y hora de la transacción.
- **Precio:** precio unitario del producto.
- **Cliente ID:** identificador único de cliente.
- **País:** país del cliente.

El archivo original está compuesto por dos hojas de cálculo, correspondientes a los períodos 2009-2010 y 2010-2011 respectivamente. El módulo `cargarDatos.py` lee ambas hojas y las concatena en un único DataFrame antes de generar una copia local en formato `.csv`.

Para la carga de los datos se desarrolló un procedimiento que lee el archivo original en formato Excel (`.xlsx`) y lo convierte a un archivo `.csv` que se guarda como una copia local. En las ejecuciones siguientes, el proceso verifica si ya existe el archivo `.csv` y en caso afirmativo lo utiliza directamente en lugar de volver a leer el Excel original. Este mecanismo reduce significativamente el tiempo de carga, dado que la lectura de archivos Excel de gran tamaño es considerablemente más lenta que la de archivos CSV de igual contenido.

El dataset original está compuesto por 1.067.371 registros y 8 características. Las fechas de las transacciones abarcan desde el 1 de diciembre de 2009 hasta el 9 de diciembre de 2011. Se identificaron 5942 clientes únicos y transacciones provenientes de 43 países distintos, con predominio de Reino Unido.

Un análisis inicial de calidad de datos reveló los siguientes puntos a resolver en la etapa de limpieza:

- **Valores nulos:** 243.007 registros (22,8 %) sin `Cliente ID` y 4382 registros (0,41 %) sin `Descripción`.
- **Duplicados:** 34.335 registros duplicados (3,22 %).
- **Cancelaciones:** 19.494 transacciones (1,83 %) corresponden a cancelaciones, identificables porque su número de factura (`Factura`) empieza con la letra “C”.
- **Valores negativos:** el atributo `Cantidad` presenta un mínimo de -80.995 unidades, y la columna `Precio` un mínimo de -\$53.594,36.

2.1.1 Limpieza de datos

A partir del análisis inicial descrito en la sección anterior, se procedió a limpiar el dataset, aplicando los siguientes filtros:

1. **Eliminación de registros sin `Customer ID`:** dado que las transacciones sin identificador de cliente no pueden asociarse a ningún segmento y se descartan.
2. **Eliminación de cancelaciones:** se eliminan las transacciones cuyo número de `Factura` comienza con la letra “C”, correspondientes a cancelaciones.
3. **Eliminación de valores inválidos:** se conservan únicamente los registros con `Cantidad` y `Precio` positivos, descartando así cantidades o precios negativos que no representan compras válidas.
4. **Eliminación de duplicados exactos:** se remueven los registros completamente duplicados.

Para entender mejor el impacto de cada filtro, podemos observar la tabla 2.1 que cuenta por separado cuántos registros cumplen cada uno de estos motivos sobre el dataset original. Hay que tener en cuenta que estos motivos no son excluyentes: un mismo registro puede cumplir varios a la vez, por ejemplo, no tener `Cliente ID` y ser también una cancelación.

Tabla 2.1: Cantidad de registros afectados por cada motivo de limpieza (dataset original).

Motivo	Registros afectados
Sin <code>Cliente ID</code>	243.007
Cancelaciones (<code>Factura</code> con “C”)	19.494
<code>Cantidad</code> negativo	22.950
<code>Precio</code> negativo	6.207

Luego de esta limpieza, el dataset pasó de 1.067.371 a 779.425 registros, es decir que se eliminó un 27,0 % de los registros originales. La cantidad de clientes únicos casi no cambió, pasando de 5942 a 5878, lo que muestra que la mayoría de los clientes tiene al menos una transacción válida después de la limpieza.

2.1.2 Análisis exploratorio: distribución geográfica

Como parte del análisis exploratorio inicial, se analizó cómo se distribuían las transacciones según el país de origen del cliente, con el objetivo de ver si había diferencias de comportamiento entre países que fueran relevantes.

Tabla 2.2: Distribución de transacciones y facturación por país (top 10)

País	Importe total	% Importe	Filas	% Filas
Reino Unido	14,389,230	82.82	700,388	89.86
Irlanda	616,570	3.55	15,565	2.00
Países Bajos	554,038	3.19	5,085	0.65
Alemania	425,020	2.45	16,432	2.11
Francia	348,769	2.01	13,511	1.73
Australia	169,284	0.97	1,789	0.23
España	108,333	0.62	3,662	0.47
Suiza	100,062	0.58	3,005	0.39
Suecia	91,516	0.53	1,317	0.17
Dinamarca	68,581	0.39	778	0.10

2.1.3 Distribución de transacciones y facturación por país

El dataset contiene registros de 43 países pero, como se puede observar en la tabla 2.2, hay una concentración muy marcada en el Reino Unido. El mismo concentra el 89.86 % de los registros del dataset y el 82.82 % de la facturación total.

La Figura 2.1 muestra los 15 países con más transacciones. Como Reino Unido domina la escala del gráfico, se agrega también la Figura 2.2, sin Reino Unido, para poder ver mejor cómo se distribuye el resto de los países.




Figura 2.1: Top 15 países por cantidad de transacciones




Figura 2.2: Top 15 países por cantidad de transacciones (excluyendo Reino Unido)

2.1.4 Comparación de comportamiento entre países

Para ver si el comportamiento de compra cambia según el país, se compararon algunos de distintas regiones, tanto en cantidad de transacciones como en el valor de las mismas. En la Tabla 2.3 se presentan estas métricas para una selección de países de distinto tamaño y ubicación geográfica.

Las comparaciones muestran un patrón que se repite en la mayoría de los pares de países analizados: los países con menos clientes y transacciones tienen un ticket promedio por factura más alto que aquellos que tienen más cantidad de clientes y transacciones. El caso más marcado es el de Países Bajos frente a Alemania: con menos de un tercio de los registros (5,085 frente a 16,432), Países Bajos tiene un ticket promedio 4.5 veces mayor (2,429.99 contra 538.68). El caso de Francia y Alemania, ambos países tienen una cantidad de registros y facturas similares entre sí, es consistente con el patrón general, sus valores de ticket promedio e importe promedio por ítem también son parecidos entre sí, lo que refuerza la idea de que la diferencia de ticket promedio está más asociada al volumen relativo de cada país que a otro factor.

La comparación entre Reino Unido y el resto del mundo, presentada en la Tabla 2.4, resulta particularmente interesante. Reino Unido concentra el 89.86 % de las transacciones, pero el resto del mundo tiene un ticket promedio por factura de 870.94, más del doble que Reino Unido (429.00), y también más ítems promedio por factura (578.05 frente a 254.39). Esto sugiere que los clientes fuera de Reino Unido tienen, en promedio, un perfil de compra más parecido al de un mayorista o distribuidor, mientras que dentro de Reino Unido el comportamiento se parece más al de un consumidor minorista.

2.2 Cálculo de RFM

A partir del dataset limpio y filtrado solamente con los registros pertenecientes a Reino Unido, se calcularon para cada cliente las tres variables que componen el modelo RFM:

- **Recencia:** cantidad de días transcurridos entre la fecha de la última compra del cliente y una fecha

Tabla 2.3: Comparación de métricas de compra entre países seleccionados

	Reino Unido	Lituania	Francia	Alemania	Emiratos Árabes	Portugal	Países Bajos	Japon	Suiza
Registros	700,388	154	13,511	16,432	383	2,356	5,085	468	3,005
Facturas únicas	33,541	6	614	789	11	93	228	33	90
Clientes únicos	5,350	1	95	107	4	24	22	10	22
Importe promedio (por línea)	20.54	31.77	25.81	25.87	24.03	23.58	108.96	91.93	33.30
Cantidad promedio (por línea)	12.18	14.97	20.01	13.70	15.25	11.64	75.49	67.61	17.38
Precio promedio	3.07	2.56	4.29	3.59	3.64	5.10	2.69	2.01	3.82
Ticket promedio por factura	429.00	815.45	568.03	538.68	836.61	597.36	2,429.99	1,303.75	1,111.80
Ítems promedio por factura	254.39	384.33	440.21	285.37	530.82	294.87	1,683.68	958.88	580.30

Tabla 2.4: Comparación: Reino Unido vs. Resto del mundo

	Reino Unido	Resto del mundo
Filas	700,388	79,037
Facturas únicas	33,541	3,428
Clientes únicos	5,350	529
Importe promedio	20.54	37.77
Cantidad promedio	12.18	25.07
Precio promedio	3.07	4.57
Importe promedio por factura	429.00	870.94
Ítems promedio por factura	254.39	578.05

de referencia fija, correspondiente al día posterior a la última transacción registrada en el dataset.

- **Frecuencia:** cantidad de facturas únicas asociadas al cliente, es decir, la cantidad de compras distintas que realizó.
- **Monto:** suma total del importe de todas las transacciones del cliente.

Este cálculo se realizó únicamente sobre los clientes de Reino Unido, dado que, como se discutió en la sección anterior, este segmento concentra la enorme mayoría de los registros y presenta un comportamiento de compra distinto al del resto del mundo, más parecido al de un consumidor minorista. El resultado es un conjunto de 5.350 clientes únicos, cada uno caracterizado por sus tres métricas RFM. La Tabla 2.5 resume la distribución estadística de estas variables.

Tabla 2.5: Estadísticas descriptivas de las variables RFM

	Recencia	Frecuencia	Monto
Media	203.00	6.27	2,689.58
Desvío estándar	209.96	12.00	11,706.53
Mínimo	1	1	2.95
25 %	26	1	330.20
50 % (mediana)	98.5	3	829.44
75 %	382	7	2,156.25
Máximo	739	336	580,987.04

Las tres variables tienen una distribución bastante asimétrica: hay una diferencia grande entre la mediana, la media y el máximo. Esto se ve más que nada en Monto, donde la mediana es de \$829,44, la media sube a \$2,689,58 y el máximo llega a \$580,987,04. Esa diferencia tan grande muestra que hay clientes que compran mucho más que el resto.

2.2.1 Escalamiento de variables

Dado que las tres variables RFM se encuentran en escalas muy distintas entre sí (días, cantidad de compras, monto en dólares), fue necesario estandarizarlas antes de aplicar cualquier algoritmo de clustering. Si no se hacía esto, el Monto iba a dominar el cálculo de distancias entre clientes, ya que tiene una magnitud mucho mayor que la Recencia o la Frecuencia, y eso iba a distorsionar los resultados. Para esto se aplicó una estandarización de tipo *z-score*, que a cada variable le resta su media y la divide por su desvío estándar, para que las tres queden centradas en cero y con varianza 1.

Tabla 2.6: Estadísticas descriptivas de las variables RFM luego del escalamiento

	Recencia	Frecuencia	Monto
Media	≈ 0	≈ 0	≈ 0
Desvío estándar	1.00	1.00	1.00
Mínimo	-0.96	-0.44	-0.23
25 %	-0.84	-0.44	-0.20
50 % (mediana)	-0.50	-0.27	-0.16
75 %	0.85	0.06	-0.05
Máximo	2.55	27.49	49.40




Figura 2.3: Distribución de las variables RFM escaladas.

En la Tabla 2.6 se puede observar que, aunque el escalamiento logra que las tres variables queden en un rango comparable en su parte central (media 0, desvío 1), los valores máximos de Frecuencia y Monto siguen siendo extremos (27.49 y 49.40 respectivamente). Esto confirma que la asimetría de estas variables no se corrigió del todo con la estandarización, sino que responde a la presencia de un pequeño grupo de clientes con un comportamiento de compra muy por encima del resto. El boxplot de la Figura 2.3 deja ver esto mismo de forma más clara: mientras que la Recencia queda bastante contenida, la Frecuencia y el Monto tienen varios puntos que se van bien lejos de la caja, sobre todo ese caso en el Monto que llega casi a 50.

2.3 Clustering

El objetivo general de este trabajo es comparar el desempeño de k -medias y DBSCAN para la segmentación de clientes en un contexto de *e-commerce*, evaluando métricas internas e interpretando las características de cada uno de los segmentos. Además de estos dos algoritmos, se agregó HDBSCAN

debido a que este algoritmo resuelve algunas de las limitaciones de DBSCAN, ya que no necesita un valor fijo de `eps` y se adapta mejor a densidades variables dentro del dataset.

En las siguientes subsecciones se describe cómo se aplicó cada uno de los tres algoritmos sobre las variables RFM escaladas, y qué criterios se utilizaron para seleccionar sus respectivos parámetros.

2.3.1 K-means

El primer algoritmo aplicado fue K-means, un método de clustering particional que agrupa las observaciones en k clusters, buscando minimizar la distancia entre cada punto y el centroide de su cluster. A diferencia de DBSCAN y HDBSCAN, K-means requiere que se especifique de antemano la cantidad de clusters a formar, por lo que el primer paso fue determinar un valor adecuado de k . Para esto se utilizó el método del codo, que consiste en ejecutar el algoritmo con distintos valores de k y registrar, en cada caso, la inercia resultante (la suma de las distancias al cuadrado entre cada punto y su centroide). A medida que k aumenta, la inercia disminuye de forma natural, pero llega un punto en el que agregar clusters adicionales deja de aportar una mejora significativa. Ese punto de quiebre, visualizado como un `godo`.^{en} el gráfico, se toma como una buena referencia para elegir k .

La Figura 2.4 muestra la inercia obtenida para valores de k entre 2 y 10. Se ve una caída pronunciada hasta $k = 4$ / $k = 5$ y, a partir de ahí la curva se va aplanando considerablemente. Tomando esto como referencia, se probó el algoritmo tanto con $k = 4$ como con $k = 5$, para comparar ambas segmentaciones y evaluar cuál resulta más interpretable y mejor separada según las métricas internas.




Figura 2.4: Método del codo para la selección de k

2.3.2 DBSCAN

El segundo algoritmo aplicado fue DBSCAN, un método de clustering basado en densidad que agrupa los puntos que están suficientemente cerca entre sí, y marca como ruido a los que quedan aislados. A diferencia de K-means, DBSCAN no necesita que se le indique de antemano la cantidad de clusters a formar; en cambio, requiere dos parámetros: `eps`, la distancia máxima entre dos puntos para que se consideren vecinos, y `min_puntos`, la cantidad mínima de vecinos que necesita un punto para ser considerado parte de un cluster. Para elegir estos parámetros se hizo una búsqueda combinando distintos valores de `eps` y `min_puntos`, y para cada combinación se registró la cantidad de clusters formados y la cantidad (y porcentaje) de puntos clasificados como ruido. Las primeras corridas, con valores de `eps` más altos, agrupaban a casi todos los clientes en un único cluster gigante, mientras que valores muy bajos de `eps` fragmentaban el dataset en decenas de clusters de apenas 3 o 4 clientes cada uno. Ninguno de estos

dos extremos resulta útil para una segmentación interpretable. La Tabla 2.7 muestra los resultados de probar distintas combinaciones de *eps* y *min_puntos* donde se ve un patrón bastante claro: a medida que *eps* crece, el algoritmo tiende a juntar todo en un solo cluster, y el porcentaje de ruido baja cada vez más. Con valores de *eps* chicos pasa lo contrario, aparecen más clusters, pero también sube el ruido. Se terminó eligiendo *eps*=0.2 y *min_puntos*=5, que da 4 clusters con un 3.40 % de ruido. Aunque hay combinaciones con menos ruido, la mayoría de esas terminan agrupando a casi todos los clientes en un único cluster, lo cual no sirve para el objetivo de armar una segmentación.

eps	min_puntos	n_clusters	n_ruido	% ruido
0.2	3	7	154	2.88
0.2	5	4	182	3.40
0.2	10	2	241	4.50
0.2	15	1	299	5.59
0.3	3	8	87	1.63
0.3	5	1	125	2.34
0.3	10	1	149	2.79
0.3	15	1	163	3.05
0.4	3	5	59	1.10
0.4	5	2	81	1.51
0.4	10	1	112	2.09
0.4	15	1	122	2.28
0.7	3	4	39	0.73
0.7	5	2	45	0.84
0.7	10	1	59	1.10
0.7	15	1	69	1.29
1.0	3	3	38	0.71
1.0	5	1	44	0.82
1.0	10	1	48	0.90
1.0	15	1	50	0.93
1.5	3	4	21	0.39
1.5	5	1	34	0.64
1.5	10	1	37	0.69
1.5	15	1	37	0.69

Tabla 2.7: Grid search de parámetros para DBSCAN.

2.3.3 HDBSCAN

El tercer algoritmo que se aplicó fue HDBSCAN. A diferencia de DBSCAN, no hace falta fijarle un valor de *eps* de antemano este en cambio, construye una jerarquía de clusters a distintos niveles de densidad y selecciona automáticamente los clusters más estables de esa jerarquía. El parámetro principal es *min_cluster_size*, el tamaño mínimo que tiene que tener un grupo para considerarse un cluster; también se puede ajustar *min_samples*, que regula qué tan estricto es el algoritmo a la hora de decidir qué es ruido. Al igual que con DBSCAN, se hizo una búsqueda combinando distintos valores de *min_cluster_size* y *min_samples*. La Tabla 2.8 muestra los resultados de probar distintas combinaciones de *min_cluster_size* y *min_samples*. Con valores bajos de *min_cluster_size* (entre 10 y 100), el algoritmo formaba muchos clusters chicos, entre 50 y 115, algo poco útil para una segmentación interpretable. A medida que se subió *min_cluster_size*, la cantidad de clusters bajó de forma consistente,

hasta llegar a valores más manejables (4 a 7 clusters) con `min_cluster_size` entre 300 y 500. Un aspecto que se mantuvo constante en toda la búsqueda fue el porcentaje de ruido, que se movió siempre entre 20 % y 39 % sin importar mucho la combinación de parámetros elegida. En un principio se había elegido `min_cluster_size=500` y `min_samples=3`, buscando una cantidad de clusters parecida a la que se usó en K-means. Pero después se probó también la combinación con menos ruido de toda la grilla de búsqueda, `min_cluster_size=200` y `min_samples=1`, para ver qué tan buena era esa alternativa.

<code>min_cluster_size</code>	<code>min_samples</code>	<code>n_clusters</code>	<code>n_ruido</code>	% ruido
100	1	15	1274	23.81
100	2	14	1406	26.28
100	3	14	1470	27.48
100	5	13	1666	31.14
100	10	10	1972	36.86
150	1	10	1195	22.34
150	2	10	1223	22.86
150	3	10	1282	23.96
150	5	10	1401	26.19
150	10	9	1846	34.50
200	1	9	1173	21.93
200	2	9	1197	22.37
200	3	8	1449	27.08
200	5	9	1576	29.46
200	10	8	2040	38.13
300	1	7	1668	31.18
300	2	7	1686	31.51
300	3	7	1718	32.11
300	5	7	1793	33.51
300	10	6	1812	33.87
500	1	5	1704	31.85
500	2	5	1723	32.21
500	3	5	1760	32.90
500	5	5	1855	34.67
500	10	4	2094	39.14

Tabla 2.8: Grid search de parámetros para HDBSCAN.

2.4 Métricas de calidad

Para evaluar la calidad de los clusters obtenidos con cada algoritmo se utilizaron tres métricas de evaluación interna. A diferencia de un problema de clasificación, en clustering no existe una respuesta correcta conocida de antemano para cada cliente, por lo que estas métricas evalúan directamente la estructura de los clusters (qué tan compactos son y qué tan separados están entre sí) en lugar de comparar contra un resultado esperado.

El coeficiente de Silhouette mide qué tan bien separado está cada punto de los demás clusters en relación a su propio cluster. La idea de fondo es simple: un punto está bien agrupado si está cerca de los demás puntos de su cluster y, al mismo tiempo, lejos de los puntos del cluster más cercano. Para cuantificar esto, para cada observación se calculan dos distancias promedio: la distancia promedio a los

puntos de su propio cluster, y la distancia promedio a los puntos del cluster vecino más cercano (es decir, el segundo cluster más parecido a esa observación). Después se calcula la diferencia entre ambas distancias, normalizada para quedar en un rango de -1 a 1 :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (2.1)$$

donde $a(i)$ es la distancia promedio entre el punto i y el resto de los puntos de su mismo cluster, y $b(i)$ es la distancia promedio entre el punto i y los puntos del cluster vecino más cercano.

El valor de $s(i)$ se puede interpretar de la siguiente manera: si $b(i)$ es mucho mayor que $a(i)$, quiere decir que el punto está mucho más cerca de su propio cluster que del cluster vecino, y $s(i)$ se acerca a 1 , lo cual indica una buena asignación. Si $a(i)$ y $b(i)$ son parecidos, $s(i)$ se acerca a 0 , lo que sugiere que el punto está en el límite entre dos clusters. Y si $a(i)$ termina siendo mayor que $b(i)$, es decir que el punto está en realidad más cerca del cluster vecino que del suyo propio, $s(i)$ toma valores negativos, lo que sugiere que probablemente fue asignado al cluster equivocado.

El coeficiente de Silhouette global de un modelo se obtiene promediando $s(i)$ sobre todas las observaciones, y sirve como una medida general de qué tan bien definida está la segmentación en su conjunto.

El índice de Davies-Bouldin evalúa la relación entre la dispersión dentro de cada cluster y la distancia entre los centros de los distintos clusters. La lógica detrás de esta métrica es que un buen cluster debería ser compacto (los puntos dentro de él no deberían estar muy dispersos) y, al mismo tiempo, debería estar bien alejado de los demás clusters. Para capturar esto, para cada cluster se busca el peor caso posible: el cluster vecino con el cual la relación entre dispersión y distancia sea más desfavorable, es decir, aquel que combine alta dispersión con poca distancia entre centroides:

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right) \quad (2.2)$$

donde k es la cantidad de clusters, σ_i es la dispersión promedio dentro del cluster i (qué tan lejos están en promedio los puntos del cluster respecto a su centroide), y $d(c_i, c_j)$ es la distancia entre los centroides de los clusters i y j .

Para cada cluster i , el término $\frac{\sigma_i + \sigma_j}{d(c_i, c_j)}$ se calcula contra todos los demás clusters j , y se queda con el valor máximo, es decir, con la peor comparación posible para ese cluster. Esto tiene sentido porque a un cluster le alcanza con estar mal separado de uno solo de sus vecinos para que se considere una segmentación problemática, aunque esté bien separado del resto. Después, el índice de Davies-Bouldin final se obtiene promediando ese peor caso entre todos los clusters.

A diferencia del Silhouette, en este caso valores más bajos indican mejor separación, ya que un buen resultado implica clusters compactos (dispersión σ_i baja) y bien distanciados entre sí (distancia $d(c_i, c_j)$ alta), lo cual hace que el cociente completo se achique.

El índice de Calinski-Harabasz, también conocido como criterio de razón de varianza, compara la dispersión entre clusters con la dispersión dentro de cada cluster. La idea es parecida a la de un análisis de varianza: si los clusters están bien definidos, los puntos deberían variar poco respecto al centro de su propio cluster (dispersión dentro), pero los centros de los distintos clusters deberían estar bastante alejados entre sí (dispersión entre clusters). El índice se calcula como:

$$CH = \frac{\text{tr}(B_k)}{\text{tr}(W_k)} \times \frac{n - k}{k - 1} \quad (2.3)$$

donde n es la cantidad total de observaciones, k la cantidad de clusters, B_k la matriz de dispersión entre clusters y W_k la matriz de dispersión dentro de los clusters.

La matriz B_k mide qué tan separados están los centroides de cada cluster respecto al centroide general de todos los datos, ponderado por la cantidad de puntos en cada cluster; su traza ($\text{tr}(B_k)$) resume esa dispersión entre clusters en un solo número. La matriz W_k , por su parte, mide qué tan dispersos están los

puntos dentro de cada cluster respecto a su propio centroide, y su traza ($\text{tr}(W_k)$) resume esa dispersión interna. El cociente $\frac{\text{tr}(B_k)}{\text{tr}(W_k)}$ da entonces una idea directa de qué tan grande es la separación entre clusters en relación a la compactación dentro de cada uno.

El factor $\frac{n-k}{k-1}$ es un ajuste que tiene en cuenta la cantidad de observaciones y de clusters, y sirve para que el índice no favorezca automáticamente a soluciones con más o menos clusters solo por la forma en que se calculan B_k y W_k , permitiendo comparar configuraciones con distinta cantidad de clusters de forma más justa.

Acá valores más altos son mejores, porque reflejan una situación en la que la dispersión entre clusters es grande en relación a la dispersión dentro de cada cluster, es decir, clusters densos y bien diferenciados entre sí.

Es importante aclarar que estas tres métricas se calcularon únicamente sobre el modelo final de cada algoritmo, y no se usaron durante la búsqueda de hiperparámetros de DBSCAN y HDBSCAN. Esto se debe a que tanto DBSCAN como HDBSCAN pueden dejar puntos sin asignar a ningún cluster, marcándolos como ruido (cluster -1), y las tres métricas mencionadas no fueron diseñadas para manejar este tipo de puntos.

En el caso del Silhouette y del índice de Calinski-Harabasz, el cálculo requiere comparar cada punto contra un cluster de referencia; si los puntos de ruido se incluyen como si fueran un cluster más, se termina midiendo la separación de un grupo que en realidad no representa ningún patrón real, sino simplemente todo lo que el algoritmo no pudo agrupar. Esto puede distorsionar el resultado tanto para bien como para mal, dependiendo de cuántos puntos caigan en esa categoría y qué tan dispersos estén. El índice de Davies-Bouldin presenta un problema similar, ya que también depende de calcular centroides y dispersiones por cluster, algo que no tiene mucho sentido para un conjunto de puntos que fueron agrupados justamente por no pertenecer a ningún cluster.

Por este motivo, usar estas métricas durante la etapa de búsqueda de hiperparámetros hubiera sido poco confiable, ya que un modelo con mucho ruido podría obtener un buen puntaje simplemente porque el ruido no está siendo evaluado correctamente, y no porque los clusters formados sean realmente buenos. Por eso se optó por evaluar los hiperparámetros de DBSCAN y HDBSCAN en base a criterios más interpretables, como la cantidad de clusters obtenidos y el porcentaje de puntos clasificados como ruido, y reservar las métricas de Silhouette, Davies-Bouldin y Calinski-Harabasz para la comparación final entre los cuatro modelos.

Capítulo 3

Resultados y discusión

3.1 Resultados de RFM escalado




Figura 3.1: Distribución de clientes según RFM.

En la Figura 3.1 se puede apreciar la distribución de los clientes según el modelo RFM escalado. La gran mayoría de los clientes se concentra cerca del origen, con valores bajos de Frecuencia y Monto, mientras que aparecen algunos pocos casos bien alejados del resto en esas dos variables, que son los mismos que ya se habían visto como outliers en el boxplot de la sección anterior. En cuanto a la Re-

cencia, los clientes se reparten de forma más pareja a lo largo de todo el eje, sin ese mismo patrón de concentración. Esta forma de la nube de puntos, una masa grande y compacta de clientes parecidos entre sí, es justamente, como se va a ver más adelante, lo que complica a algoritmos como DBSCAN a la hora de separar bien los grupos. Por eso, como se va a analizar en la siguiente sección, conviene también mirar la distribución de a pares de variables.

3.2 Resultados de K-means

Se ejecutó K-means con $k = 4$ y con $k = 5$, tal como se planteó en la metodología. Para cada cluster se calcularon los promedios de Recencia, Frecuencia y Monto, para poder interpretar qué tipo de cliente representa cada grupo.

K-means con $k = 4$

Tabla 3.1: Resumen de clusters: K-means con $k = 4$

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
0	1,842	462.79	2.19	683.60
1	34	26.26	104.62	80,479.43
2	3,473	67.00	7.43	2,825.44
3	1	1.00	145.00	580,987.04




Figura 3.2: Distribución de clientes según K-Means: $k=4$.

Como podemos ver tanto en la Tabla 3.1 como en la Figura 3.2, el cluster 2 es el más numeroso, con 3.473 clientes: compran cada dos meses aproximadamente y gastan en promedio \$2.825,44, un perfil de

cliente activo y regular. El cluster 0, con 1.842 clientes, agrupa a quienes hace mucho que no compran (462 días en promedio) y con un gasto bajo, lo que sugiere clientes inactivos o perdidos. El cluster 1, más chico (34 clientes), es el grupo de mayor valor: compran seguido (más de 100 facturas en promedio) y gastan muy por encima del resto, cerca de \$80.479 en promedio. Por último, el cluster 3 queda formado por un único cliente, con un monto total de \$580.987,04 y 145 facturas, muy por encima de cualquier otro cliente de la base. Este resultado es consistente con lo discutido en la sección de escalamiento, donde ya se había identificado la presencia de un cliente con valores de compra extremos respecto al resto.

Para complementar la vista en tres dimensiones, también se armaron gráficos de a pares de variables, que permiten ver mejor cómo quedan separados los grupos. En la Figura 3.3 se aprecia bastante bien la diferencia entre los clusters: el grupo con mayor recencia y baja frecuencia queda claramente aparte del resto, mientras que el cluster más numeroso se concentra en valores bajos de recencia. Al mirar los pares Figuras 3.4 y 3.6 que incluyen el Monto, aparece de nuevo el mismo problema que se vio en el escalamiento: hay un cliente con un monto tan alto que el resto de los puntos queda apretado contra el eje, y no se distinguen bien los clusters. Por eso se armó una segunda versión de cada gráfico, dejando fuera de la vista ese valor extremo, sin sacarlo del análisis, solo de la imagen, para poder ver mejor cómo se separan los demás clusters. Se puede ver en las versiones con zoom Figuras 3.5 y 3.7 que casi no aparecen los clusters de mayor monto y frecuencia, ya que son justamente los que quedan afuera del recorte pero no porque hayan desaparecido, sino porque son los valores más altos que se dejaron fuera a propósito.






Figura 3.3: Clusters ($k=4$) según Recencia y Frecuencia.

Figura 3.4: Clusters ($k=4$) según Frecuencia y Monto.**K-means con $k = 5$** Tabla 3.2: Resumen de clusters: K-means con $k = 5$

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
0	3,240	74.82	5.36	1,794.78
1	21	23.86	125.62	103,602.85
2	1,773	470.49	2.17	678.72
3	315	28.48	30.31	14,647.99
4	1	1.00	145.00	580,987.04

Por ootro lado, podemos ver en la Tabla 3.2 y en la Figura 3.8 que con $k = 5$, los clusters de clientes inactivos (cluster 2) y de clientes regulares (cluster 0) se mantienen prácticamente iguales a los obtenidos con $k = 4$. La diferencia más importante está en el cluster de alto valor que teníamos con $k = 4$ el cual aquí se divide en dos. Por un lado queda un grupo chico de 21 clientes con un comportamiento de compra extremo, con 125 facturas y \$103.602 de gasto promedio. Por otro lado queda un grupo más grande, de 315 clientes, que también compran seguido y gastan bastante (30 facturas y \$14.647,99 en promedio), pero no tanto como el grupo anterior. Esto permite ver con más detalle a los clientes de mayor valor, algo que con $k = 4$ quedaba todo junto en un solo cluster. Al igual que con $k = 4$, aparece el cluster 4 que contiene solamente al mismo cliente con valores muy altos.

Con $k=5$, la separación entre los clientes queda un poco más afinada. En la Figura 3.9 aparece un grupo nuevo que con $k=4$ no se distinguía tanto: clientes con recencia baja o media y algo más de frecuencia que el resto, que forman una franja propia entre el grupo más inactivo y el más numeroso. Al igual que con $k=4$, el cliente con el monto extremo vuelve a tapar la diferencia entre los clusters en los gráficos que incluyen el monto, tanto para la Figura 3.10 y 3.12, así que se armaron las mismas versiones con zoom para este caso. En la Figura 3.11 se nota mucho mejor cómo quedan los tres grupos principales:

Figura 3.5: Clusters ($k=4$) según Frecuencia y Monto, con zoom.

uno con los montos más altos, otro en un nivel intermedio, y el más numeroso con los montos más bajos. Lo mismo se repite al mirar la Recencia en la Figura 3.13, donde esa separación se ve bastante más prolija que la que se había obtenido con $k=4$.

3.3 Resultados de DBSCAN

Tabla 3.3: Resumen de clusters: DBSCAN ($\text{eps}=0.2$, $\text{min_puntos}=5$)

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
Ruido (-1)	182	126.33	42.05	32,350.80
0	5,153	205.49	4.98	1,638.17
1	7	324.57	12.00	4,051.40
2	4	71.50	28.50	3,881.86
3	4	405.25	11.50	4,004.72

Observando la Tabla 3.3, que muestra el resumen de los clusters que se obtuvo con estos parámetros incluyendo el grupo de ruido (etiqueta -1), y la Figura 3.14 se ve el problema: el cluster 0 se queda con 5.153 de los 5.350 clientes, casi todos los registros. Los clusters 1, 2 y 3 son grupos de 4 a 7 clientes solamnete, así que no sirven mucho para segmentar. Lo más llamativo pasa en el grupo de ruido. Esos 182 clientes tienen en promedio 42 compras y \$32.350,80 de monto, muy por encima del resto. O sea, DBSCAN no armó un cluster para los clientes de mayor valor, sino que los dejó afuera como ruido, porque no cumplían el criterio de densidad que fijan eps y min_puntos .

Esto muestra una limitación de DBSCAN con este tipo de datos: como usa un solo valor de eps para todo el dataset, no logra adaptarse tanto a la zona densa de clientes habituales como a los clientes con comportamiento extremo. Estos últimos terminan casi todos como ruido en vez de agruparse. Esta





Figura 3.6: Clusters ($k=4$) según Recencia y Monto.

limitación es la que lleva a probar HDBSCAN en la siguiente sección.

Para DBSCAN se armaron los mismos gráficos de a pares de variables. Acá el resultado es bastante distinto al de K-means. Como se puede observar en la Figura 3.15 se ve que casi todos los clientes quedan metidos en un solo grupo, el Cluster 0, que se concentra en recencia baja y frecuencia baja. El resto de los puntos, los que tienen algún valor más alto o más raro en cualquiera de las variables, caen en el Cluster -1, que no es en realidad un grupo de clientes parecidos entre sí, sino los casos que el algoritmo no pudo asignar a ningún cluster (ruido). Esto se nota todavía más al mirar el Monto: en la Figura 3.16 los clusters 1, 2 y 3 son grupitos muy chicos, casi no se llegan a ver, y en la Figura 3.17 vuelve a aparecer el mismo cliente con el monto extremo, esta vez catalogado como ruido. En el fondo, lo que está haciendo DBSCAN acá no es separar a los clientes en distintos perfiles de comportamiento, sino más bien diferenciar entre los que se parecen a la mayoría y los que no. Esto confirma lo que ya se había visto al probar distintas combinaciones de *eps* y *min_puntos*: no hay ninguna configuración que logre armar grupos parejos y con sentido para el negocio, como sí se consigue con K-means.

Figura 3.7: Clusters ($k=4$) según Recencia y Monto, con zoom.

3.4 Resultados de HDBSCAN

HDBSCAN con $\text{min_cluster_size} = 500, \text{min_samples} = 3$

Tabla 3.4: Resumen de clusters: HDBSCAN ($\text{min_cluster_size}=500, \text{min_samples}=3$)

Cluster	Clientes	Recencia prom. (días)	Frecuencia prom.	Monto prom.
Ruido (-1)	1,760	227.15	13.00	6,401.98
0	550	48.21	7.20	2,176.17
1	1,146	122.09	3.74	1,072.27
2	520	108.38	2.00	599.32
3	627	133.36	1.00	300.04
4	747	508.52	1.00	262.74

A diferencia de DBSCAN, observando la Tabla 3.4 y la Figura ?? se puede ver que acá los clusters tienen tamaños mucho más parejos, entre 520 y 1.146 clientes cada uno, y se pueden diferenciar bastante bien entre sí. El cluster 0 agrupa a los clientes más activos: compraron hace poco (48 días en promedio) y con una frecuencia relativamente alta (7.2 compras). El cluster 4, en el otro extremo, junta a los clientes más inactivos: hace más de 500 días que no compran y solo hicieron una compra en total. Los clusters 2 y 3 son parecidos entre sí, ambos con clientes de baja frecuencia (1 a 2 compras) y montos bajos, pero se diferencian en la recencia. El grupo de ruido vuelve a ser el más interesante: son 1.760 clientes, casi un tercio de los registros totales, con un monto promedio de \$6.401,98, muy por encima de cualquiera de los clusters formados. Esto confirma lo que se planteó en la metodología: HDBSCAN no fuerza a estos clientes de comportamiento más variado a entrar en algún grupo, sino que los deja afuera como puntos que no encajan claramente en ninguna densidad definida. Con HDBSCAN el resultado se ve distinto a lo que pasaba con DBSCAN. Acá el ruido (Cluster -1) no se concentra solamente en los casos más raros o




Figura 3.8: Distribución de clientes según K-Means: $k=5$.

extremos, sino que aparece repartido a lo largo de todo el rango de recencia, como se ve en la Figura 3.19 hay clientes marcados como ruido tanto entre los que compraron hace poco como entre los que hace mucho que no vuelven. Los cinco clusters que sí arma el algoritmo, en cambio, quedan todos agrupados en frecuencia y monto bajos, bastante pegados entre sí, algo que se repite tanto en la Figura 3.20 como en la Figura 3.22. Por eso, al igual que se hizo con K-means, se armó una versión con zoom de estos dos gráficos, dejando afuera de la vista al cliente con el monto más alto. En la Figura 3.21 se ve que los cinco clusters no están mezclados entre sí, sino que se ordenan en franjas bastante marcadas, cada uno con un rango distinto de frecuencia y monto, quedando casi como escalones desde los clientes con menor actividad de compra hasta los que más compran y más gastan dentro de este grupo. Lo mismo se aprecia mirando la Recencia en la Figura 3.23, donde esa misma separación en franjas se mantiene.

La Figura 3.24 muestra el árbol condensado que construye HDBSCAN a partir del árbol de expansión mínima. En esta figura, el eje vertical representa el valor de λ (inversamente proporcional a la distancia), y el ancho de cada rama indica la cantidad de puntos que la componen. Se puede ver cómo, a medida que aumenta λ es decir, a medida que se pide más densidad, todos los clientes se van separando en ramas cada vez más finas. Al principio del gráfico se desprende una rama ancha que junta a la mayoría de los clientes, y más abajo esa rama se divide en varias más chicas que llegan hasta el final del árbol. Esas son las que HDBSCAN termina eligiendo como clusters finales. Las ramas que se cortan antes de llegar al final son agrupaciones que el algoritmo no consideró lo bastante estables como para ser un cluster, y esos puntos terminan como ruido.

HDBSCAN con $\text{min_cluster_size} = 200, \text{min_samples} = 1$

Con esta configuración, los nueve clusters muestran una especie de gradiente de valor de cliente, como puede verse en la Tabla 3.5 y en la Figura 3.18. En un extremo están el Cluster 0 y el Cluster 1, con la recencia más baja y la frecuencia más alta del grupo, son los clientes que compran seguido y hace poco, algo que se aprecia bien en la Figura 3.26. En el otro extremo aparecen el Cluster 2 y el Cluster 8,




Figura 3.9: Clusters ($k=5$) según Recencia y Frecuencia.

con recencias arriba de los 400 días y apenas una o dos compras en total, que representan a los clientes prácticamente perdidos. En el medio se ubican el resto de los clusters, con distintas combinaciones de recencia y frecuencia que van marcando ese pasaje de un extremo al otro. Los clusters 3, 4, 5 y 6 completan ese pasaje entre los dos extremos, y aunque a simple vista parecen parecidos entre sí, tienen matices que los distinguen. El Cluster 4 y el Cluster 5 tienen la recencia más baja de este grupo intermedio (86 y 83 días) junto con una frecuencia moderada (5 y 4 compras), lo que los deja como clientes activos aunque no tan seguido como los del Cluster 0 o el Cluster 1. El Cluster 3, en cambio, tiene una recencia bastante más alta (108 días) pero solo 2 compras en promedio, mientras que el Cluster 6 es el que más se acerca al extremo de clientes perdidos dentro de este grupo intermedio, con una recencia de 164 días y apenas 3 compras. En conjunto, estos cuatro clusters muestran que entre cliente activo y cliente perdido no hay un corte tajante, sino una transición bastante gradual. Vale la pena remarcar el caso del Cluster -1: a diferencia de lo que suele pasar, acá el ruido no representa a los clientes menos valiosos, sino todo lo contrario: tiene el monto promedio más alto de todos los grupos (\$8.700 aproximadamente), muy por encima de cualquiera de los nueve clusters, tal como se ve en las Figuras 3.27 y 3.29. Esto tiene sentido porque HDBSCAN termina descartando como ruido a los casos que no encajan bien en ningún patrón, y entre esos casos atípicos hay varios clientes de compra muy grande que no logran agruparse entre sí por ser pocos y no tener un comportamiento parecido. En cuanto a los gráficos, se armó una versión con zoom de los que incluyen el Monto, dejando afuera de la vista al cliente con el monto más alto. En la Figura 3.28 se ve que los nueve clusters se ordenan en franjas bastante marcadas según su frecuencia y monto. Esto se aprecia todavía mejor en la Figura 3.30, donde se nota algo particular: el Cluster 7 y el Cluster 8 agrupan a clientes que compraron una sola vez, pero quedan bien separados por la recencia: el Cluster 7 son clientes que compraron hace relativamente poco (recencia promedio de 133 días), mientras que el Cluster 8 son clientes que probaron una vez y nunca más volvieron (recencia promedio de casi 509 días). Es una distinción que con menos clusters no se llegaba a ver, y que tiene bastante sentido para pensar estrategias de recontacto distintas para cada uno de estos dos grupos.




Figura 3.10: Clusters ($k=5$) según Frecuencia y Monto.

3.5 Evaluación de los modelos

La Tabla 3.6 muestra los resultados de las tres métricas utilizadas para comparar los distintos modelos: Silhouette, Davies-Bouldin y Calinski-Harabasz. K-means con $k=5$ es el que mejor puntúa en las tres, seguido por K-means con $k=4$. DBSCAN queda muy por detrás en todos los casos, lo cual confirma la limitación que ya se había visto en los gráficos: al concentrar casi todos los clientes en un único cluster, no logra una segmentación real. Un resultado que vale la pena remarcar es que, entre las dos configuraciones de HDBSCAN, la que mejor puntúa en las métricas es la primera ($\text{min_cluster_size}=500$, $\text{min_samples}=3$), a pesar de que se había probado también la segunda configuración ($\text{min_cluster_size}=200$, $\text{min_samples}=1$) por dar una segmentación con más sentido para el negocio. Esto tiene que ver con que estas métricas premian clusters compactos y bien separados entre sí. La configuración de 9 clusters, en cambio, encuentra matices más finos entre los clientes, como la distinción entre compradores únicos recientes y perdidos, que valen la pena desde el punto de vista del negocio, aunque las métricas internas no lo reflejen tan bien. En conjunto, K-means con $k=5$ se queda como el modelo con mejor desempeño según estas métricas, lo cual coincide con que fue el más fácil de interpretar y el que dio una segmentación más pareja a lo largo de todo el análisis.




Figura 3.11: Clusters ($k=5$) según Frecuencia y Monto, con zoom.




Figura 3.12: Clusters ($k=5$) según Recencia y Monto.




Figura 3.13: Clusters ($k=5$) según Recencia y Monto, con zoom.




Figura 3.14: Distribución de clientes según DBSCAN.




Figura 3.15: Clusters DBSCAN según Recencia y Frecuencia.




Figura 3.16: Clusters DBSCAN según Frecuencia y Monto.




Figura 3.17: Clusters DBSCAN según Recencia y Monto.




Figura 3.18: Distribución de clientes según HDBSCAN - $\min_cluster_size = 500$, $\min_samples = 3$.




Figura 3.19: Clusters HDBSCAN según Recencia y Frecuencia.




Figura 3.20: Clusters HDBSCAN según Frecuencia y Monto.




Figura 3.21: Clusters HDBSCAN según Frecuencia y Monto, con zoom.




Figura 3.22: Clusters HDBSCAN según Recencia y Monto.




Figura 3.23: Clusters HDBSCAN según Recencia y Monto, con zoom.




Figura 3.24: Jerarquía de clusters construida por HDBSCAN

Cluster	Cantidad de clientes	Recencia promedio	Frecuencia promedio	Monto promedio
-1	1173	203.25	16.69	8700.18
0	218	30.29	10.96	3299.60
1	575	49.19	7.22	2249.39
2	313	467.77	2.00	533.26
3	520	108.38	2.00	599.32
4	277	86.28	5.00	1511.66
5	317	83.15	4.00	1126.10
6	575	164.57	3.00	902.58
7	633	132.91	1.00	313.56
8	749	508.62	1.00	266.35

Tabla 3.5: Perfil de los clusters obtenidos con HDBSCAN ($min_cluster_size=200$, $min_samples=1$).




Figura 3.25: Distribución de clientes según HDBSCAN - $min_cluster_size = 200$, $min_samples = 1$.

Modelo	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means (k=4)	0.5757	0.5073	3842.37
K-Means (k=5)	0.6000	0.5653	4581.65
DBSCAN	-0.0368	1.0570	7.13
HDBSCAN (500/3)	0.1412	3.8249	2219.82
HDBSCAN (200/1)	-0.0290	4.6234	1686.66

Tabla 3.6: Comparación de métricas de evaluación entre los distintos modelos.




Figura 3.26: Clusters HDBSCAN (200/1) según Recencia y Frecuencia.




Figura 3.27: Clusters HDBSCAN (200/1) según Frecuencia y Monto.




Figura 3.28: Clusters HDBSCAN (200/1) según Frecuencia y Monto, con zoom.




Figura 3.29: Clusters HDBSCAN (200/1) según Recencia y Monto.




Figura 3.30: Clusters HDBSCAN (200/1) según Recencia y Monto, con zoom.

Capítulo 4

Conclusiones

En este trabajo se analizó y comparó el desempeño de los algoritmos de clustering K-means, DBSCAN e HDBSCAN combinados con el modelo RFM (Recencia, Frecuencia, Monto) para la segmentación de clientes de un comercio minorista en línea (Online Retail II).

A lo largo del desarrollo se observaron diferencias significativas en la forma en que cada método procesa la información y estructura los grupos, arribando a las siguientes conclusiones principales:

- **Desempeño de K-means en métricas de evaluación interna:** El algoritmo K-means con $k = 5$ presentó los mejores indicadores cuantitativos entre los modelos evaluados, alcanzando un coeficiente de Silhouette de 0,6000, un índice de Davies-Bouldin de 0,5653 y un valor de Calinski-Harabasz de 4581,65. Estas métricas reflejan que K-means logró construir grupos bien delimitados y internamente compactos, delimitando de manera limpia a los clientes inactivos, los compradores habituales y las distintas categorías de mayor gasto.
- **Dificultades de DBSCAN ante datos con densidad variable:** La configuración probada de DBSCAN ($\epsilon = 0,2$, `min_puntos=5`) mostró limitaciones para generar una segmentación equilibrada. El algoritmo concentró al 96,3% de la base de usuarios en un solo clúster general y marcó como ruido a casi la totalidad de los clientes con mayor frecuencia y gasto. Este resultado confirma en la práctica la dificultad de DBSCAN para responder a conjuntos de datos donde la densidad varía fuertemente entre la masa principal de usuarios y los compradores de mayor valor.
- **Relación entre métricas matemáticas y utilidad comercial en HDBSCAN:** Aunque HDBSCAN registró puntajes más bajos en los índices de evaluación sintéticos —debido a la forma en que estas métricas penalizan la presencia de puntos de ruido o fronteras irregulares—, la variante con `min_cluster_size=200` y `min_samples=11` aportó una perspectiva muy útil desde el punto de vista del análisis de negocio. Esta configuración permitió descomponer la base en 9 gradientes que reflejan con detalle las etapas intermedias entre un cliente activo y uno perdido, diferenciando, por ejemplo, a los compradores ocasionales recientes de aquellos que no registran actividad desde hace tiempo.
- **Gestión de valores extremos y clientes corporativos:** Un aspecto relevante del enfoque por densidad en HDBSCAN fue su tratamiento de las observaciones atípicas. Mientras que en K-means la presencia de un cliente con un volumen de compra excepcional (\$580.987,04) genera un clúster de un único integrante y condiciona la escala del resto, HDBSCAN clasifica a estos usuarios con perfiles de compra extremos dentro de la categoría de ruido junto a otros clientes de facturación elevada (con un promedio cercano a los \$8.700). De este modo, se evita distorsionar la agrupación de los clientes de consumo regular.

A partir de los resultados obtenidos, se concluye que no existe un único algoritmo superior en todos los aspectos, sino que sus aportes resultan complementarios:

- Para la gestión operativa y la automatización de campañas de marketing general, K-means ($k = 5$) se presenta como la opción más adecuada por su simplicidad, rápido cómputo y consistencia en los indicadores de separación.
- Por su parte, HDBSCAN constituye una herramienta analítica valiosa para explorar la estructura profunda de los datos, aislar automáticamente cuentas corporativas o mayoristas y diseñar estrategias específicas de recontacto orientadas a subgrupos con hábitos de compra particulares.