

Título

Autor:

Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)



Índice general

Índice de Figures	3
Índice de Tablas	5
1. Introducción	11
1.1. Motivación	11
1.2. Estado del Arte	11
1.3. Conjuntos de Datos	11
2. Metodología	13
2.0.1. Dataset	13
2.0.2. Limpieza de datos	14
2.1. Análisis exploratorio: distribución geográfica	14
2.1.1. Distribución de transacciones y facturación por país	14
2.1.2. Comparación de comportamiento entre países	15
2.1.3. Discusión de resultados	16
3. Resultados y discusión	19
4. Conclusiones	21
Bibliografía	21

Índice de Figuras

2.1. Top 15 países por cantidad de transacciones	15
2.2. Top 15 países por cantidad de transacciones (excluyendo Reino Unido)	16

Índice de Tablas

2.1. Cantidad de registros afectados por cada motivo de limpieza (dataset original).	14
2.2. Distribución de transacciones y facturación por país (top 10)	15
2.3. Comparación: United Kingdom vs. Resto del mundo	16

Resumen

Capítulo 1

Introducción

1.1 Motivación

1.2 Estado del Arte

1.3 Conjuntos de Datos

Capítulo 2

Metodología

2.0.1 Dataset

En el trabajo se utiliza el conjunto de datos *Online Retail II*, publicado en el repositorio UCI Machine Learning Repository. Contiene el registro de transacciones de una tienda minorista con sede en el Reino Unido, especializada en la venta de artículos de regalo para todo tipo de ocasiones, con una base de clientes compuesta principalmente por mayoristas.

El dataset abarca transacciones realizadas entre diciembre de 2009 y diciembre de 2011. Está compuesto por las siguientes variables:

- **Factura:** número de factura, identifica cada transacción.
- **Código de Artículo:** código de producto.
- **Descripción:** descripción del producto.
- **Cantidad:** cantidad de unidades vendidas por transacción.
- **Fecha de Factura:** fecha y hora de la transacción.
- **Precio:** precio unitario del producto.
- **Cliente ID:** identificador único de cliente.
- **País:** país del cliente.

El archivo original está compuesto por dos hojas de cálculo, correspondientes a los períodos 2009-2010 y 2010-2011 respectivamente. El módulo `cargarDatos.py` lee ambas hojas y las concatena en un único DataFrame antes de generar una copia local en formato `.csv`.

Para la carga de los datos se desarrolló el módulo `cargarDatos.py`, que lee el archivo original en formato Excel (`.xlsx`) y lo convierte a un archivo `.csv` que se guarda como una copia local. En las ejecuciones siguientes, el módulo verifica si ya existe el archivo `.csv` y en caso afirmativo lo utiliza directamente en lugar de volver a leer el Excel original. Este mecanismo reduce significativamente el tiempo de carga, dado que la lectura de archivos Excel de gran tamaño es considerablemente más lenta que la de archivos CSV de igual contenido.

El dataset original está compuesto por 1.067.371 registros y 8 características. Las fechas de las transacciones abarcan desde el 1 de diciembre de 2009 hasta el 9 de diciembre de 2011. Se identificaron 5942 clientes únicos y transacciones provenientes de 43 países distintos, con predominio de Reino Unido.

Un análisis inicial de calidad de datos reveló los siguientes puntos a resolver en la etapa de limpieza:

- **Valores nulos:** 243.007 registros (22,8 %) sin **Cliente ID** y 4382 registros (0,41 %) sin **Descripción**.

- **Duplicados:** 34.335 registros duplicados (3,22 %).
- **Cancelaciones:** 19.494 transacciones (1,83 %) corresponden a cancelaciones, identificables porque su número de factura (**Factura**) empieza con la letra “C”.
- **Valores negativos:** el atributo **Cantidad** presenta un mínimo de -80.995 unidades, y la columna **Precio** un mínimo de -\$53.594,36.

2.0.2 Limpieza de datos

A partir del análisis inicial descrito en la sección anterior, se implementó el módulo `limpieza_datos.py`, encargado de limpiar el dataset. La función `limpiarDatos` aplica los siguientes filtros:

1. **Eliminación de registros sin Customer ID:** dado que las transacciones sin identificador de cliente no pueden asociarse a ningún segmento y se descartan.
2. **Eliminación de cancelaciones:** se eliminan las transacciones cuyo número de **Factura** comienza con la letra “C”, correspondientes a cancelaciones.
3. **Eliminación de valores inválidos:** se conservan únicamente los registros con **Cantidad** y **Precio** positivos, descartando así cantidades o precios negativos que no representan compras válidas.
4. **Eliminación de duplicados exactos:** se remueven los registros completamente duplicados.

Para entender mejor el impacto de cada filtro, se armó la función `resumenLimpieza`, que cuenta por separado cuántos registros cumplen cada uno de estos motivos sobre el dataset original. Hay que tener en cuenta que estos motivos no son excluyentes: un mismo registro puede cumplir varios a la vez, por ejemplo, no tener **Cliente ID** y ser también una cancelación.

Tabla 2.1: Cantidad de registros afectados por cada motivo de limpieza (dataset original).

Motivo	Registros afectados
Sin Cliente ID	243.007
Cancelaciones (Factura con “C”)	19.494
Cantidad negativo	22.950
Precio negativo	6.207

Luego de esta limpieza, el dataset pasó de 1.067.371 a 779.425 registros, es decir que se eliminó un 27,0 % de los registros originales. La cantidad de clientes únicos casi no cambió, pasando de 5942 a 5878, lo que muestra que la mayoría de los clientes tiene al menos una transacción válida después de la limpieza.

2.1 Análisis exploratorio: distribución geográfica

Como parte del análisis exploratorio inicial, se analizó cómo se distribuían las transacciones según el país de origen del cliente, con el objetivo de ver si había diferencias de comportamiento entre países que fueran relevantes.

2.1.1 Distribución de transacciones y facturación por país

El dataset contiene registros de 43 países, con una concentración muy marcada en el Reino Unido. La Tabla 2.2 resume, para los diez países con mayor facturación, la cantidad de registros y el importe total generado, en términos absolutos y porcentuales.

Tabla 2.2: Distribución de transacciones y facturación por país (top 10)

País	Importe total	% Importe	Filas	% Filas
Reino Unido	14,389,230	82.82	700,388	89.86
Irlanda	616,570	3.55	15,565	2.00
Países Bajos	554,038	3.19	5,085	0.65
Alemania	425,020	2.45	16,432	2.11
Francia	348,769	2.01	13,511	1.73
Australia	169,284	0.97	1,789	0.23
España	108,333	0.62	3,662	0.47
Suiza	100,062	0.58	3,005	0.39
Suecia	91,516	0.53	1,317	0.17
Dinamarca	68,581	0.39	778	0.10

Reino Unido concentra el 89.86 % de los registros del dataset y el 82.82 % de la facturación total.

La Figura 2.1 muestra los 15 países con más transacciones. Como Reino Unido domina la escala del gráfico, se agrega también la Figura 2.2, sin Reino Unido, para poder ver mejor cómo se distribuye el resto de los países.




Figura 2.1: Top 15 países por cantidad de transacciones

2.1.2 Comparación de comportamiento entre países

Para profundizar en el comportamiento de los clientes en los diferentes países, se compararon pares de países, calculando para cada uno: cantidad de filas, facturas únicas, clientes únicos, importe promedio, cantidad promedio, precio promedio, ticket promedio por factura, e ítems promedio por factura.




Figura 2.2: Top 15 países por cantidad de transacciones (excluyendo Reino Unido)

	Reino Unido	Lituania	Francia	Alemania	Emiratos Árabes	Portugal	Países Bajos	Japon	Suiza
Registros	700,388	154	13,511	16,432	383	2,356	5,085	468	3,005
Facturas únicas	33,541	6	614	789	11	93	228	33	90
Clientes únicos	5,350	1	95	107	4	24	22	10	22
Importe promedio (por línea)	20.54	31.77	25.81	25.87	24.03	23.58	108.96	91.93	33.30
Cantidad promedio (por línea)	12.18	14.97	20.01	13.70	15.25	11.64	75.49	67.61	17.38
Precio promedio	3.07	2.56	4.29	3.59	3.64	5.10	2.69	2.01	3.82
Ticket promedio por factura	429.00	815.45	568.03	538.68	836.61	597.36	2,429.99	1,303.75	1,111.80
Ítems promedio por factura	254.39	384.33	440.21	285.37	530.82	294.87	1,683.68	958.88	580.30

Tabla 2.3: Comparación: United Kingdom vs. Resto del mundo

	United Kingdom	Resto del mundo
Filas	700,388	79,037
Facturas únicas	33,541	3,428
Clientes únicos	5,350	529
Importe promedio	20.54	37.77
Cantidad promedio	12.18	25.07
Precio promedio	3.07	4.57
Importe promedio por factura	429.00	870.94
Ítems promedio por factura	254.39	578.05

2.1.3 Discusión de resultados

Las comparaciones muestran un patrón que se repite en la mayoría de los pares de países analizados: los países con menos clientes y transacciones tienen un ticket promedio por factura más alto que aquellos que tienen más cantidad de clientes y transacciones (Tabla 2.1.2). El caso más marcado es el de Países

Bajos frente a Alemania: con menos de un tercio de los registros (5,085 frente a 16,432), Países Bajos tiene un ticket promedio 4.5 veces mayor (2,429.99 contra 538.68). Se ve un patrón parecido, aunque menos marcado, entre Japón y Suiza, y entre Reino Unido y Lituania.

En el caso de Francia y Alemania, ambos países tienen una cantidad de registros y facturas similares entre sí (a diferencia de los pares anteriores, donde uno de los dos era claramente más chico). Consistente con el patrón general, sus valores de ticket promedio e importe promedio por ítem también son parecidos entre sí, lo que refuerza la idea de que la diferencia de ticket promedio está más asociada al volumen relativo de cada país que a otro factor.

La comparación entre Emiratos Árabes y Portugal refuerza el mismo patrón: aunque Emiratos Árabes tiene muchos menos registros, facturas y clientes que Portugal, su ticket promedio por factura es más alto (836.61 frente a 597.36) y tiene casi el doble de ítems promedio por factura (530.82 frente a 294.87).

La comparación más interesante es la de Reino Unido contra el resto del mundo (Tabla 2.3). Reino Unido concentra el 89.86% de las transacciones, pero el resto del mundo tiene un ticket promedio por factura de 870.94, más del doble que Reino Unido (429.00), y también más ítems promedio por factura (578.05 frente a 254.39). Esto sugiere que los clientes fuera de Reino Unido tienen, en promedio, un perfil de compra más parecido al de un mayorista o distribuidor, mientras que dentro de Reino Unido el comportamiento se parece más al de un consumidor minorista.

Capítulo 3

Resultados y discusión

Capítulo 4

Conclusiones